
지역/연령별 가계자금 금액 및
금융자산 보유를 기반으로 한
지역/연령별 투자 전략 이해를 위한
다변량 자료분석
(PCA, FA, CA를 중심으로)

팀
동학개미모임

팀 장
안 중 찬(JungChan Ann)
부산대학교 자연과학대학 통계학과

팀 원
장 원(Jang Won)
충북대학교 사회과학대학 경제학과

□ 요약

위 보고서의 주제는 ‘지역/연령별 가계자금 금액 및 금융자산 보유를 기반으로 한 지역/연령별 투자 전략 이해를 위한 다변량 자료분석 (PCA, FA, CA를 중심으로)’이다. 즉, 지역/연령별 가계자금 금액 및 금융자산 보유의 특징을 먼저 연구하고, 그러한 연구를 기반으로 투자 전략을 이해하는 것이 순서가 되겠다. 이러한 데이터를 이해하는데 사용되는 기법은 빅데이터 분석에서 많이 범용적으로 사용되는 PCA, FA, CA이다.

코로나 19로 인해 세계 전반으로 증시가 하락하였고, 코스피는 1480선 가까이 하락하였다. 하지만, 이후 빠른 상승세를 보이면서 코스피가 최저점 기준 60%이상이 오르는 데에는 소액 개인 투자자인 동학 개미가 있기 때문에 가능한 이야기였다. 원래 우리나라 주식시장에서는 주식 투자에서 기관과 외인이 굉장히 큰 역할을 하고, 개인 투자자는 그러한 흐름에 따라서 투자를 하는 추세가 강했으나, 동학개미운동으로 인해서 그러한 추세는 깨졌다.

하지만, 우리는 이런 동학개미운동의 의의와 개인 투자자의 성공한 이유를 찾고자 하는 연구가 아니라, 동학개미운동의 투자 규모에 초점을 맞추었다. 동학개미운동은 2020년 3월의 폭락장에서 기관과 외국인의 매도 매물을 개인투자자들이 공격적으로 매수하면서 증시 반등을 성공시킨 사건이다. 이 때, 개인 투자자가 사들인 주식의 규모가 굉장히 크기 때문에, 다양한 연령층과 지역에서 투자를 했을 것이라고 판단하였다. 이 때, 연령층과 지역의 차이는 개개인의 투자성향의 차이를 보여줄 것이라고 판단하여, 이러한 연구를 시작하였다.

데이터에 대한 특징이 명확하지 않고, 분산되어 있는 데이터에 대해 특징을 파악하고 공통성 있는 데이터끼리 군집을 만드는 분석기법 중 가장 적합한 분석기법은 PCA(주성분 분석), FA(인자 분석), CA(군집 분석)가 가장 효과적이라고 판단하였다. 이 때, FA중 MLFA는 고려하지 않았는데, 그 이유는 위의 두 데이터가 다변량 정규성을 만족하지 않기 때문이다. 이 때, ‘지역 및 연령별 10대소비(가계자금) 금액 및 금융자산 데이터’에 대한 6개의 변수는 PCA와 PCFA를 통하여 경제활동 영위수준, 생활자금 소비, 미래 대비 정도라는 3개의 변수로 압축시켜서 각 관측치에 대해서 두드러진 특징을 파악한 후, 3개의 변수에 대해서 CA로 군집화 시켜서 각 군집에 대한 특징을 파악하였다.

또한, “[2021금융데이터경진대회] 동학개미운동 신규 고객 투자 정보“ 데이터의 분석에 필요한 변수 11개를 정리한 후, 나머지 변수에 해당하는 관측값은 제외시키고 분석을 진행했는데, 앞의 절차와 마찬가지로, PCA, FA 를 통해 11개의 변수를 투자수요, 여유자금, 안정성 선호도라는 3개의 변수로 압축시켜 각 관측치에 대한 특성을 파악하고, 3개의 변수에 대해서 CA로 군집화 시켜서 각 군집에 대한 특성을 파악하였다.

두 데이터에 대한 군집화를 한 이후, 주식에 대한 수요, 주식에 대한 자산, 안정성 성향, 생활수준 요구 정도, 미래 대비도에 대해서 각각의 관측치에 대해 순위를 지정한 후, 다시 CA를 통하여 군집을 형성시켜 정리하였다. 이 때, 이러한 연령/지역별 성향에 맞춰서 투자의 방향을 제시하면서 결론을 도출하였다. 이에 대한 결과는 요약 보고서에 수록하기에 너무 많은 내용을 담고 있으므로, ‘C. 결론’을 참조하여야 한다. 이 때, ‘C. 결론’에 있는 ‘<C.표1.두 데이터를 통합했을 때의 군집 분할>’에서 지역/연령별 주식에 대한 수요, 주식에 대한 자산, 안정성 성향, 생활수준 요구정도, 미래대비도를 파악할 수 있다. 즉, 연구에 대한 목표를 달성 한 것이다.

이러한 연구로 인해서, 첫째, 각 군집의 특징에 맞는 적절한 주식 상품을 구성할 수 있을 것이다. 즉, 지역 및 연령 별 특징을 파악함으로써 상품 판매를 위한 더 효율적이고 매력적인 구성이 가능해질 것이다. 둘째, 역선택을 감소시킬 수 있을 것이다. 즉, 이 연구대로 개개인의 상황에 맞는 투자 상품을 기획한다면, 개개인의 상황과 맞지 않게 구성된 주식 상품은 자연스럽게 시장에서 퇴출되고, 효율적인 상품만 남아서 시장 내 양화를 구축할 가능성이 있다. 셋째, 주식상품 판매 수익 개선의 가능성을 열어준다. 각 군집의 특징에 맞는 적절한 주식 상품을 구성하고, 역선택의 문제를 해결한다면, 불필요한 주식 상품의 공급이 줄고, 소비자에 대한 정보의 비대칭이 해소되어 주식 상품 판매 수익의 개선 가능성을 열어준다. 이 때, 투자 성향에 대한 상품파악을 ‘<4.표1.두 데이터를 통합했을 때 투자 성향에 대한 상품 파악>’의 예시대로 진행한다면, 이러한 기대효과를 모두 충족시킬 수 있을 것이다. 투자 성향에 대한 상품 파악을 한 결과는 요약 보고서의 수록하기에 분량이 너무 크므로 생략하였다.

목차

1. 주제

2. 배경 및 필요성

3. 아이디어 제안 및 분석 결과

A. 지역/연령별 가계자금 금액 및 금융자산 보유의 특징 이해를 위한 다변량 자료분석

1. Data Description

- i . 전반적인 데이터 설명
- ii . 관측치에 대한 설명
- iii . 변수에 대한 설명

2. Data Description

- i . 원본 데이터 특성 파악
- ii . 다변량 정규성 파악

3. Principal Component Analysis(PCA)

- i . 공분산행렬과 상관행렬의 선택
- ii . 주성분 개수의 선택
- iii . 주성분 해석
- iv . 주성분 점수의 산점도
- v . 주성분 행렬도

4. Factor Analysis (FA)

- i . 공동 인자 개수 구하기
- ii . PCFA
- iii . MLFA

5. Cluster Analysis (CA)

- i . 계층적 군집분석
- ii . 비계층적 군집분석

6. 결론

B. 동학개미운동을 통한 지역/연령별 투자 전략을 이해하기 위한 다변량 자료 분석

1. Data Description

- i . 전반적인 데이터 설명
- ii . Tidy Data
- iii . 관측치에 대한 설명
- iv . 변수에 대한 설명

2. Data Description

- i . 원본 데이터 특성 파악
- ii . 다변량 정규성 파악

3. Principal Component Analysis(PCA)

- i . 공분산행렬과 상관행렬의 선택
- ii . 주성분 개수의 선택
- iii . 주성분 해석
- iv . 주성분 점수의 산점도
- v . 주성분 행렬도

4. Factor Analysis (FA)

- i . 공동 인자 개수 구하기
- ii . PCFA
- iii . MLFA

5. Cluster Analysis (CA)

- i . 계층적 군집분석
- ii . 비계층적 군집분석

6. 결론

C. 결론

4. 기대효과

5. 활용 데이터

6. 참고자료

1. 주제

이 연구의 주제는 ‘지역/연령별 가계자금 금액 및 금융자산 보유를 기반으로 한 지역/연령별 투자 전략 이해를 위한 다변량 분석 (PCA, FA, CA를 중심으로)’이다. 이 때, 주제에서 언급한 순서대로, 지역/연령별 가계자금 금액 및 금융자산 보유를 먼저 연구한 후, “[2021금융데이터경진대회] 동학개미운동 신규 고객 투자 정보“ 데이터에서 지역/연령별 투자 전략을 이해하기 위한 연구를 진행한 후, 이 두 연구를 종합해서 결론을 내는 것이 우리의 목표이다.

이 때, ‘(PCA, FA, CA를 중심으로)’의 의미는 연구를 함에 있어서 빅데이터에서 특징을 추출하는데 가장 보편적으로 사용되는 PCA(주성분 분석), FA(인자분석)를 사용하고, 이러한 특징들을 찾아낸 후, 같은 특징을 가진 데이터끼리 묶어내는 CA(군집분석)를 사용하겠다는 것이다.

2. 배경 및 필요성

동학개미 운동이 일어나면서, 많은 사람들이 주식 투자에 관심을 갖게 되었다. 주식에 관심을 가진 만큼, 지역/연령에 상관없이 많은 사람들이 주식에 투자하게 되었고, 이 시기에 주식을 투자한 데이터를 보면, 지역/연령별 투자 성향을 파악할 수 있다고 판단했다. 동학개미 운동이야 말로 우리나라 사람들이 가장 주식에 관심을 가졌던 시기이고, 가장 투자가 활성화된 시기이기 때문에, 투자에 대한 표본의 스펙트럼이 가장 넓고, 이러한 데이터가 투자에 대한 성향을 판단하는데 가장 적기라고 생각하였다. 이 데이터로 우리는 주식에 대한 수요, 주식에 대한 투자용의 자금, 안정성 선호 정도는 파악할 수 있지만, 이러한 투자 성향이 왜 발현되었는지는 이 데이터를 가지고 알 수 없을 것이다. 이러한 성향이 왜 나타났는지 알기 위해서는 지역/연령별 생활수준(그 연령대와 지역에서 살아가기 위해서 필요한 비용)과 미래에 대한 대비 정도를 파악해야 될 것이라고 생각하였다. 그 결과, 우리는 이 두 데이터에 대한 분석을 실시한 후, 특징을 파악하고, 이러한 특징들을 순위 데이터로 변환시킨 후, 다시 투자에 대한 성향을 파악하는 것이 가장 최적의 연구방법이라고 판단했다.

위의 연구는 지역/연령별 투자 성향을 판단하여, 투자를 문의하는 고객들에게 그에 맞는 투자 상품을 권유할 수 있고, 고객은 투자 상품에 만족감이 크게 늘어날 것이다. 이러한 매뉴얼이 없다면, 고객에게 투자를 권유할 때 고객의 성향과 맞지 않는 상품을 추천하여 고객 유치수가 줄어들 수도 있고, 고객의 자산수준(생활수준에 따른)과 미래에 대한 대비정도와 맞지 않는 상품을 추천하여 투자가 순조롭게 진행되지 않을 수도 있을 것이다. 이러한 잘못된 투자 방향 제시를 줄이기 위해서 이 연구는 필요하다.

3. 아이디어 제안 및 분석 결과

A. 지역/연령별 가계자금 금액 및 금융자산 보유의 특징 이해를 위한 다변량 자료 분석

1. Data

i. 전반적인 데이터 설명

‘지역 및 연령별 10대 소비(가계자금) 금액 및 금융자산’ 데이터는 농협은행에서 만든 데이터 자료로써, 연령별로는 10대, 20대, 30대, 40대, 50대, 60대, 70대 이상으로 나누고, 대한민국의 지역을 총 17개로 분류 (강원, 경기, 경남, 경북, 광주, 대구, 대전, 부산, 서울, 세종, 울산, 인천, 전남, 전북, 제주, 충남, 충북, 총 8도, 1 특별자치도, 1 특별광역시, 1 특별자치시, 6광역시)하여, 2020년 12월 말을 기준으로 공과금 평균 소비금액, 생활자금 평균 소비금액, 세금 평균 소비금액, 연금 평균 소비금액과 같은 소비(가계자금)금액의 평균을 조사하고, 총 저축 평균 잔액, 총 대출 평균잔액과 같은 금융자산을 조사한 데이터 자료이다.

ii 관측치에 대한 설명

이 때, 연령대와 시도명의 경우, 데이터분석을 용이하게 하기 위해서 1~119까지의 숫자로 라벨링하였다. 그 내역은 아래와 같다.

obs	연령대	obs	시도명	obs	시도명	obs	연령대	시도명
100	10대	1	강원	1	8	부산	15	제주
200	20대	2	경기	2	9	서울	16	충남
300	30대	3	경남	3	10	세종	17	충북
400	40대	4	경북	4	11	울산		
500	50대	5	광주	5	12	인천		
600	60대	6	대구	6	13	전남		
700	70대	7	대전	7	14	전북		

즉, 백의 자리 수는 연령대를 나타내고, 십의자리, 일의자리는 시도를 나타낸다고 할 수 있다.

iii 변수에 대한 설명

utility bills	공과금 평균 소비금액, 공과금이란, 조합비, 협회비, 적십자회비 등과 같이 영업에 관계되는 공공적 지출로써, 제조원가에 포함되지 않는 것을 말한다. 이 때, 이 변수는 어느 특정 한 연령대와 지역의 모든 공과금 납부금액을 평균 낸 수치를 설명해준다.
livingfund	생활자금 평균 소비금액, 생활자금이란, 경제 생활을 영위하는데 쓰는 자금으로써, 이 변수는 어느 특정 한 연령대와 지역의 모든 생활자금을 평균 낸 수치를 설명해준다.
tax	세금 평균 소비금액, 세금이란, 재산세, 자동차세, 공제받지 못한 매입 부가가치세 등의 세 부담액을 말한다. 이 변수는 어느 특정 한 연령대와 지역의 모든 세금을 평균 낸 수치를 설명해준다.
annaul pension	연금 평균 소비금액, 연금이란, 정기적인 소득이 더 이상 없을 때 개인에게 해마다 소득을 제공하는 돈을 가리키는 것으로, 여기서 연금 소비금액이란, 이러한 연금을 받기 위해서 소비하는 금액을 말한다. 이 때, 이 변수는 어느 특정한 연령대와 지역의 모든 연금 소비 금액을 평균 낸 수치를 설명해준다.
savings	총 저축 평균 잔액, 저축이란, 소득 중에서 소비되지 않고 생산 활동의 밑천이 되는 나머지 자산을 말하는데, 여기서 이 변수는 어느 특정한 연령대와 지역의 모든 총 저축 잔액을 평균낸 수치를 설명해준다.
loan	총 대출 평균 잔액. 이 때 이 변수는 어느 특정한 연령대와 지역의 모든 총 대출을 평균낸 수치를 설명한다.

이 때, 이 자료를 수치적으로 요약한 것은 그림 1.1과 같다.


utility bills	livingfund	tax
Min. :17536	Min. : 0	Min. : 0
1st Qu.:38791	1st Qu.:39023	1st Qu.:168455
Median :42986	Median :44873	Median :184808
Mean :42130	Mean :42847	Mean :177919
3rd Qu.:46354	3rd Qu.:47556	3rd Qu.:194795
Max. :54685	Max. :70618	Max. :229175
annual pension	savings	loan
Min. : 28095	Min. : 778187	Min. : 0
1st Qu.:113446	1st Qu.: 7341547	1st Qu.: 6841892
Median :132926	Median :14745002	Median : 16188412
Mean :124897	Mean :13406626	Mean : 18322982
3rd Qu.:143869	3rd Qu.:18363682	3rd Qu.: 21931990
Max. :180345	Max. :31762950	Max. :100486097

표 1.1. 자료의 수치적 요약

2. Data Description

i. 원본 데이터 특성 파악

우리의 목표는 연령별, 지역별 가계자금 금액 및 금융자산에 대한 특징을 알고 싶은 것이므로, 변수들 간의 상관성을 파악하기 위해서 Scatter Plot을 사용할 것이다. 이 결과는 그림 2.1에 나타나있다.



또한, 이를 더 수치적으로 파악하기 위해서 상관행렬을 고려해볼 수도 있다. 이 결과는 표 2.1에서 볼 수 있다.

	utility.bills <dbl>	livingfund <dbl>	tax <dbl>	annual.pension <dbl>	savings <dbl>	loan <dbl>
utility bills	1.00000000	0.07120925	0.2568150	0.0452608	0.31101510	0.06939073
livingfund	0.07120925	1.00000000	0.3471503	-0.1885601	-0.07843406	0.30992138
tax	0.25681497	0.34715028	1.00000000	0.2773212	0.36473763	0.28747369
annual pension	0.04526080	-0.18856012	0.2773212	1.00000000	0.72517428	0.42761766
savings	0.31101510	-0.07843406	0.3647376	0.7251743	1.00000000	0.30851033
loan	0.06939073	0.30992138	0.2874737	0.4276177	0.30851033	1.00000000

표 2.1. 상관행렬

이 때, 상관행렬에서 annual pension과 savings가 강한 양의 상관관계를 보이는 것으로 보아, 두 변수는 비슷한 성질을 가지고 있다는 사실을 알 수 있다. 이는 연금과 저축이 같은 성질을 가지고 있는 변수라고도 할 수 있는데, 미래를 위해서 연금을 쌓고 저축을 한다는 것을 봤을 때, 두 변수를 같은 성질을 가진다는 것이 적절하다. 또한, tax와 utility bills와 tax와 loan사이에는 약한 상관관계가 존재하므로, 이 조합 사이에서도 어떠한 관계가 있다는 것을 유추해볼 수 있으며, livingfund는 위의 여러 조합들을 고려하여볼 때, 위의 조합을 제외하고서 큰 상관관계를 보이는 조합이 없는 것으로 판단된다. 이렇게, 변수들 간의 특성이 서로 어느 정도의 상관관계를 가지고 있으므로, PCA나 FA같은 R-technique을 사용하여 새로운 변수를 찾아서 데이터를 분석하는 것이 가능하다고 파악된다. 또한, 상관행렬에서 데이터를 보았을 때 어느 정도의 군집을 이루고 있다고 할 수 있는데, 어떻게 군집을 이루고 있는지는 모르기 때문에, 변수에 특성에 따라서 CA와 같은 Q-technique를 시도해야한다. 그렇기 때문에 우리는 PCA, FA를 모두 사용하고, 그 방법들을 비교해보면서 최적의 분석방법을 찾아야 할 것이다.

ii. 다변량 정규성 파악

다변량 정규성에 대한 가정은 MLFA를 수행하는데 기본적으로 필요한 가정이다. 이 데이터가 다변량 정규성을 만족하지 않는다면, PCA나 PCFA를 통하여 분석을 실시하여야 하나, 만약 다변량 정규성을 만족한다면, MLFA로도 분석을 시행해 볼 수 있을 것이다. raw data를 놓고 보았을 때 다변량 정규성을 만족하는지 확인하기 위해서 mardia test를 시행하였고, 결과에 대한 qq-plot은 그림 2.2에, 정규성 검정의 수치적인 결과는 표 2.2에 정리되어 있다.

\$multivariateNormality						
Test	Statistic	p value		Result		
1 Mardia skewness	1100.62284311586	9.63916430910151e-194		NO		
2 Mardia kurtosis	43.9644801779765	0		NO		
3 MVN	<NA>	<NA>		NO		
\$univariateNormality						
Test	Variable	Statistic	p value	Normality		
1 Shapiro-wilk	utility bills	0.9602	0.0014	NO		
2 Shapiro-wilk	livingfund	0.7893	<0.001	NO		
3 Shapiro-wilk	tax	0.6011	<0.001	NO		
4 Shapiro-wilk	annual pension	0.9138	<0.001	NO		
5 Shapiro-wilk	savings	0.9641	0.0029	NO		
6 Shapiro-wilk	loan	0.8388	<0.001	NO		
\$Descriptives						
	n	Mean	Std.Dev	Median	Min	Max
utility bills	119	42130.18	6178.766	42986	17536	54685
livingfund	119	42846.71	8294.296	44873	0	70618
tax	119	177919.06	33999.663	184808	0	229175
annual pension	119	124896.51	30426.188	132926	28095	180345
savings	119	13406626.34	6763841.343	14745002	778187	31762950
loan	119	18322981.82	17504852.780	16188412	0	100486097
	25th	75th	Skew	Kurtosis		
utility bills	38791.0	46353.5	-0.84706930	1.3192107		
livingfund	39023.0	47555.5	-2.09977866	10.4610968		
tax	168454.5	194795.0	-3.73178909	16.6419141		
annual pension	113446.0	143869.0	-0.97545363	0.5056422		
savings	7341547.0	18363682.5	-0.06711766	-0.7586418		
loan	6841892.0	21931990.0	1.76486399	4.2223493		

표 2.2. raw data에 대한 정규성 검정의 수치적인 결과

이 때, 왜도와 첨도에서 모두 다변량 정규성을 가지지 않고, 모든 변수에서 일변량 정규성을 가지지 않는다는 사실을 알 수 있다. 이는 다변량 정규성을 만족하지 않아 MLFA를 시행할 수 없다는 결론을 가진다. 하지만, PCA를 통하여 새로운 변수 역할을 하는 주성분이 직교성을 만족하는 고유벡터 행렬에 의한 직교변환을 통하여 주성분 점수행렬을 얻고, 그에 대해서 다변량 정규성 검정을 실시하면 약간은 다른 결과를 얻을 수 있다. qq-plot은 그림 2.3에서, 정규성 검정의 수치적인 결과는 표 2.3에서 확인할 수 있다.

\$multivariateNormality						
	Test	Statistic	p value		Result	
1	Mardia Skewness	1100.62284311586	9.63916430910151e-194	0	NO	NO
2	Mardia Kurtosis	43.9644801779765	<NA>	<NA>	NO	NO
3	MVN	<NA>	<NA>	<NA>	NO	NO
\$univariateNormality						
	Test	Variable	Statistic	p value	Normality	
1	shapiro-wilk	Column1	0.9487	2e-04	NO	
2	shapiro-wilk	Column2	0.8508	<0.001	NO	
3	shapiro-wilk	Column3	0.9834	0.1504	YES	
4	shapiro-wilk	Column4	0.8286	<0.001	NO	
5	shapiro-wilk	Column5	0.7320	<0.001	NO	
6	shapiro-wilk	Column6	0.9861	0.26	YES	
\$Descriptives						
	n	Mean	Std.Dev	Median	Min	Max
1	119	-4.390037e-17	1.5284302	-0.36783147	-3.291687	4.4249106
2	119	4.417313e-16	1.1745263	0.29422460	-5.812697	2.5959859
3	119	-3.176403e-16	1.0138606	0.06191718	-3.045740	2.7990844
4	119	-4.113365e-16	0.8007115	-0.12452169	-1.790707	3.6298122
5	119	-4.128874e-17	0.6378395	-0.07211915	-3.830556	1.9142745
6	119	-1.713994e-16	0.4459489	-0.05822923	-1.389039	0.9423539
	25th	75th	Skew	Kurtosis		
1	-1.0201322	0.9260768	0.62551279	0.154974576		
2	-0.7440065	0.6743685	-1.85164896	7.341022147		
3	-0.7460829	0.7734524	-0.06627204	0.115557661		
4	-0.4613973	0.1502440	1.95056535	5.676181210		
5	-0.2097006	0.1759743	-1.58355514	13.125233707		
6	-0.2735312	0.3480099	-0.21071779	-0.003671204		

표 2.3. 주성분 점수행렬에 대한 정규성 검정의 수치적인 결과

주성분 점수행렬에 대한 정규성 검정을 실시하였을 때 역시 다변량 정규성을 따르지 않는다는 사실을 알지만, 3,6번 변수에서 일변량 정규성을 따른다는 사실을 알 수 있다. 이는 상당히 큰 변화를 이루었다고 할 수 있는데, raw data에서는 0%의 변수들이 정규성을 가지고 있지 않았기 때문이다. 그러므로, MLFA도 해볼 가치가 있다고 파악된다.




그림 2.2. raw data에 대한 qq-plot




그림 2.3. 주성분 점수행렬에 대한 qq-plot

3. Principal Component Analysis(PCA)

i. 공분산행렬과 상관행렬의 선택


PCA를 시작하기 전에, 지역 및 연령별 10대 소비(가계자금) 금액 및 금융자산 데이터가 PCA 수행과정에서 상관행렬이 적합한지, 공분산행렬이 적합한지를 알아야한다. 이 때, 각 변수들의 단위를 알고, 서로의 공분산의 크기가 크게 차이가 나지 않는다면, 공분산 행렬을 사용하고, 단위를 모르고, 서로의 공분산의 크기가 크게 차이가 난다면, 상관행렬을 사용해야 한다. 이 때, 지역 및 연령별 10대 소비(가계자금) 금액 및 금융자산 데이터는 단위는 모두 '원(W)'으로 모두 같지만, 공분산의 크기가 심하게 차이 나는 것을 확인할 수 있다. 이는 표 3.1에서 확인가능하다. 즉, 상관행렬을 이용하여 PCA를 진행해야 한다는 사실을 안다.

	utility.bills <dbl>	livingfund <dbl>	tax <dbl>	annual.pension <dbl>	savings <dbl>	loan <dbl>
utility bills	38177146	3649368	53950651	8508862	1.299800e+10	7.505189e+09
livingfund	3649368	68795341	97897511	-47585747	-4.400253e+09	4.499762e+10
tax	53950651	97897511	1155977117	286883299	8.387810e+10	1.710926e+11
annual pension	8508862	-47585747	286883299	925752887	1.492393e+11	2.277517e+11
savings	12998002484	-4400252549	83878102805	149239348575	4.574955e+13	3.652764e+13
loan	7505188824	44997617387	171092582999	227751700455	3.652764e+13	3.064199e+14

표 3.1. raw data의 공분산 행렬

ii. 주성분 개수의 선택

지역 및 연령별 10대 소비(가계자금) 금액 및 금융자산 데이터는 총 6개의 변수로 이루어진 데이터이다. 이 변수들의 차원을 줄이기 위해 PCA를 실시하는데, 주성분의 개수를 구하는 방법에는 설명비율과, 이 설명비율을 시각적으로 볼 수 있는 Scree Plot이 존재한다. 설명비율에 대한 결과는 표 3.2에서, Scree Plot은 그림 3.1에서 확인할 수 있다.

<table border="1"> <thead> <tr> <th></th><th>설명비율</th></tr> </thead> <tbody> <tr> <td>주성분 1</td><td>38.91</td></tr> <tr> <td>주성분 2</td><td>23.22</td></tr> <tr> <td>주성분 3</td><td>17.10</td></tr> <tr> <td>주성분 4</td><td>10.70</td></tr> <tr> <td>주성분 5</td><td>6.78</td></tr> <tr> <td>주성분 6</td><td>3.30</td></tr> </tbody> </table>		설명비율	주성분 1	38.91	주성분 2	23.22	주성분 3	17.10	주성분 4	10.70	주성분 5	6.78	주성분 6	3.30	
	설명비율														
주성분 1	38.91														
주성분 2	23.22														
주성분 3	17.10														
주성분 4	10.70														
주성분 5	6.78														
주성분 6	3.30														
표 3.2. 설명비율	그림 3.1. Scree Plot														

이 때, 설명비율은 70%를 넘으면 주성분 분석을 실시할 수 있는데, 주성분 3개의 설명비율을 더하면 79.23%가 되므로, 주성분을 3개 사용하여 분석하는 것이 맞다. 또한, Scree Plot을 생각하면, 팔꿈치가 3번째 주성분에 있다는 것을 확인할 수 있으므로(2~4에서 팔꿈치가 있다는 사실을 알 수 있는데, 현재 Scree Plot에서 팔꿈치를 확인하는 것이 굉장히 까다로우므로, 설명비율을 보았을 때, 2~4번 중 3번에 팔꿈치가 있다는 것이 신빙성이 있는 주장이라고 할 수 있을 것이다.) 3개의 주성분을 사용하는 것이 최적의 방법임을 알 수 있다.

iii. 주성분 해석

	PC1	PC2	PC3
x1	-0.25	0.13	0.82
x2	-0.12	0.75	-0.15
x3	-0.43	0.35	0.14
x4	-0.51	-0.40	-0.23
x5	-0.55	-0.29	0.12
x6	-0.42	0.21	-0.47

표 3.3. 주성분 계수

표 3.3은 주성분 계수를 나타내는 표이다. 이 때, 첫 번째 주성분의 경우, 모든 변수에 대한 부호가 동일하므로, 이는 모든 변수에 대한 평균 금액을 나타내는 제 1 주성분이라는 것을 할 수 있다. 이 주성분의 설명력은 표 3.2.에서 확인할 수 있는데, 그 값은 38.91%이다.

두 번째 주성분의 경우 두 번째 변수에 대한 주성분 계수의 값이 유독 크다는 것을 알 수 있고, 이에 해당하는 변수는 livingfund(생활자금) 변수이다. 즉, 두 번째 주성분의 경우 생활자금에 대한 정보를 제공해준다는 것을 알 수 있다. 이 주성분의 설명력은 23.22%라는 사실을 알 수 있다.

세 번째 주성분의 경우 첫 번째 변수에 대한 주성분 계수의 값이 유독 크다는 것을 알 수 있고, 이에 해당하는 변수는 utiltiy bills(공과금) 변수이다. 즉, 세 번째 주성분의 경우 공과금에 대한 정보를 제공해준다는 것을 알 수 있고, 설명력은 17.10%라는 것을 알 수 있다.

iv. 주성분 점수의 산점도





그림 3.2. 첫 번째 주성분과 두 번째 주성분에 대한 주성분 점수 산점도
우선, 첫 번째 주성분과 두 번째 주성분으로 이루어진 주성분 점수 산점도를 확인한다. 이 결과는 그림 3.2.에 있다.

첫 번째 주성분은 모든 변수들에 대한 평균금액을 나타낸다고 했다. 이는 어떤 한 관측 값의 경제활동을 영위할 수 있는 수준이라고 할 수 있다. 소비금액(가계자금)이 작고 금융자산이 없는 사람들이 오른쪽으로, 소비금액이 크고 금융자산이 많은 사람들이 왼쪽으로 분포할 것이다. 두 번째 변수는 생활 자금에 대해 설명해주는 변수라고 할 수 있는데, 위에 분포할수록 생활 자금 소비가 많은 사람이라는 것을 알 수 있고, 아래에 있을수록 생활자금 소비가 적은 사람이라고 할 수 있다. 오른쪽에는 10대가 몰려있다는 사실을 알 수 있고, 10대는 경제활동을 영위할 수 있는 수준이 낮다고 이야기 할 수 있다. 왼쪽에는 40대, 50대가 몰려있고, 40대 50대는 경제활동을 영위할 수 있는 수준이 높다는 것을 알 수 있다. 마지막으로 30대, 60대, 70대 이상이 가운

데에 분포하고 있는데, 이들을 경제활동을 영위할 수 있는 수준이 모든 연령층에서 중간정도에 있다고 볼 수 있다. 즉, 고수준, 중수준 저수준으로 군집을 나눌 수 있다는 것을 확인하였다.

다음으로, 위쪽에는 10대부터 50대가 몰려있다는 사실을 확인할 수 있는데, 10대부터 50대까지는 생활자금 소비가 많다는 것을 알 수 있고, 60대, 70대는 아래쪽에 몰려있어 생활자금 수준이 낮다는 것도 파악이 가능하다.

이 때, 10대와 20대는 경제활동 영위수준이 낮으면서 생활자금 소비가 많은 연령이라고 할 수 있고, 30대부터 50대까지는 경제활동 수준이 높으면서 생활자금 소비가 많은 연령, 60대와 70대 이상은 경제활동 수준이 높으면서 생활자금 소비가 낮은 연령이라고 할 수 있다. 이 때, 아주 특징적인 값은 대전의 10대와 광주의 10대, 세종의 10대라고 할 수 있는데, 이들은 경제활동 영위 수준이 낮으면서 생활자금 소비가 낮은 것으로 보아, 다른 지역 10대보다 경제관념이 높다고 평가할 수 있다.



두 번째로, 첫 번째 주성분과 세 번째 주성분으로 이루어진 주성분 점수 산점도를 확인한다. 이 결과는 그림 3.3.에 있다.

첫 번째 주성분은 모든 변수들에 대한 평균금액을 나타낸다고 했다. 이는 어떤 한 관측 값의 경제활동을 영위할 수 있는 수준이라고 할 수 있다. 소비금액(가계자금)이 작고 금융자산이 없는 사람들이 오른쪽으로, 소비금액이 크고 금융자산이 많은 사람들이 왼쪽으로 분포할 것이다. 세 번째 변수는 공과금에 대해 설명해주는 변수라고 할 수 있는데, 위에 분포할수록 공과금 소비가 많은 사람이라는 것을 알 수 있고, 아래

에 있을수록 공과금 소비가 적은 사람이라고 할 수 있다.

첫 번째 주성분에 관한 오른쪽과 왼쪽의 분포는 위에서 설명했던 바와 같다.

다음으로, 위쪽에는 10대, 60대, 70대 이상이 몰려있다는 사실을 확인할 수 있는데, 10대, 60대, 70대 이상은 공과금 소비가 많다는 것을 알 수 있고, 20대부터 50대까지는 아래쪽에 몰려있어 공과금 소비가 낮다는 것도 파악이 가능하다.

정리하면, 공과금 소비가 많으면서 경제활동 영위수준이 낮은 연령대는 오른쪽 위에서 관측되는 10대들이고, 공과금소비가 적으면서 경제활동 영위수준이 낮은 연령대는 오른쪽 아래에 있는 20대들이며, 경제활동 수준이 높으면서 공과금 소비가 많은 연령은 왼쪽 위에서 관측되는 50대부터 70대들이며, 경제활동 수준이 높으면서 공과금 소비가 낮은 연령은 30대와 40대라고 할 수 있다. 이 때, 마찬가지로 특징적인 관측치를 관측할 수 있는데, 공과금소비가 적으면서 경제영위활동 수준이 낮은 전남의 10대와 세종의 10대이다. 이들은 다른 10대들과는 공과금 소비량이 다르다는 것을 알 수 있다.




마지막으로, 두 번째 주성분과 세 번째 주성분으로 이루어진 주성분 점수 산점도를 확인한다. 이 결과는 그림 3.4.에 있다.

두 번째 주성분에 따라 분류하면, 생활자금에 대한 소비에 따라서, 오른쪽에 있는 사람들이 생활자금 소비가 많고, 왼쪽에 있는 사람들이 생활자금 소비가 낮다고 할 수 있다. 또한 위쪽에 있는 사람이 공과금 소비가 크고, 아래쪽에 있는 사람이 공과금 소비가 낮다고 할 수 있다.

이 때, 생활자금에 대한 소비가 크고 공과금에 대한 소비도 큰 연령은 오른쪽 위에서 관측 가능한 10대, 40대 이고, 생활자금에 대한 소비가 크면서 공과금에 대한 소비가 낮은 연령은 오른쪽 아래에서 관측 가능한 30대와 40대이며, 생활자금에 대한 소비가 작으면서 공과금에 대한 소비가 큰 연령은 60대와 70대이다. 이 때, 50대는 가운데에 분포하고 있어, 어느 곳에 속해있다고 확인할 수 없다.

v. 주성분 행렬도

이 때, 확실한 분석을 위해서 주성분 행렬도를 만들면, 그림 3.5와 같은 결과가 나오는 것을 확인할 수 있다.



주성분 행렬도의 화살표를 먼저 보면, 화살표의 각도가 가까운 변수들은 서로 관련이 큰 변수이고, 화살표의 각도가 먼 변수들은 서로 관련이 없는 변수이다. 이 때, (연금 평균 소비금액과 총 저축 평균 금액), (공과금 평균 소비액, 총 대출 평균 금액, 세금

평균 금액)은 서로 관련이 큰 변수이고, 생활자금 평균금액은 다른 어떤 것과도 관련이 크지 않은 변수라는 사실을 알 수 있다.

이 때, 화살표의 방향에 따라서, 아래로 갈수록 생활자금 평균 소비금액이 크고, 왼쪽 아래로 갈수록 공과금 평균 소비액, 세금평균금액 (우리는 이를 세금과 공과라고 표현한다)과 총 대출 평균금액이 크며, 왼쪽 위로 갈수록 연금 평균 소비금액과 총 저축 평균 잔액이 크다는 사실을 알 수 있다.


또한, 첫 번째 주성분은 경제활동 영위 수준이 고수준인지, 저수준인지를 나타내는 주성분이고, 두 번째 주성분의 경우 생활자금 소비와 관련된 주성분으로, 아래로 갈수록 생활자금 소비가 크다는 사실을 알 수 있다.

이를 기준으로 관측치를 파악하면, 60대, 70대들은 생활자금 소비가 작으면서, 연금 평균 소비금액과 총 저축 평균 잔액이 높다는 것을 알 수 있다. 즉 미래를 위해서 기본적인 생활 소비를 줄이고 연금에 지속적으로 투자를 하며, 미래를 위해서 저축을 많이 해놓는다는 것을 알 수 있다. 50대, 40대들은 공과금 평균 소비금액과 세금 평균 소비금액, 총 대출 평균 금액이 크다는 것을 알 수 있으며, 이는 대출을 받아서 부동산과 같은 자산을 매입하는 가장 활발한 시기라는 것을 암시하게 해준다. 10대부터 20대까지는 생활자금 평균 소비금액이 크다는 사실을 알 수 있다. 이 때, 10대부터 20대까지는 생활자금 소비를 많이하고, 30대부터 50대는 대출을 많이 하면서 지출하는 세금과 공과가 크다는 것을 알 수 있으며, 60대와 70대는 총 저축 평균잔액과 연금 평균 소비금액이 크다는 것도 알 수 있다. 이 때, 예외로 존재하는 세종 10대, 광주 10대, 대전 10대는 생활자금 소비가 크지 않으면서 경제활동 영위수준이 낮다.

4. Factor Analysis (FA)

i. 공동 인자 개수 구하기


앞에서(1. Data Description i. 전반적인 데이터 설명) 우리는 분석을 행할 때 상관행렬을 사용해야한다는 사실을 알 수 있었고, 그러므로, 상관행렬을 스펙트럴 분해하여 설명비율을 구해준 후, 공동 인자의 개수를 확인한다. 그에 대한 수치적 결과는 설명비율로, 시각적인 결과는 Scree Plot을 통해서 확인가능하다.




이 때, 앞에서의 (3. Principal Component Analysis(PCA) ii. 주성분 개수의 선택)의 결과와 같다는 것을 알 수 있는데, 앞에서의 분석과 지금의 분석에서 모두 스펙트럴 분해를 이용하여 분석하였기 때문이다. 세 번째 공동인자까지의 설명비율이 79.23%이고, Scree Plot의 팔꿈치가 3번에서 이루어지는 것을 확인할 수 있으므로, 3개의 공동인자를 사용하여 FA를 수행한다.

ii. PCFA

PCFA를 수행하여 인자 적재 그림을 통해 변수들의 특성을 파악해본 후, 인자 점수 그림으로 관측치를 분석하는 절차가 이루어져야 하므로, 우선 인자 적재그림을 통해 변수들의 특성을 파악해본다. 1번째 공동인자와 두 번째 공동인자, 1번째 공동인자와 3번째 공동인자, 2번째 공동인자와 3번째 공동인자에 대한 인자적재그림은 그림 3.2.에서 확인 가능하다.



또한 이에 대한 인자 점수 그림은 그림 4.3에서 확인가능하다.



이 때, 1번, 2번 공동인자의 인자적재그림에서는 오른쪽 위로 갈수록 세금과 공과, 대출의 소비금액이 크고, 오른쪽 아래로 갈수록 저축액과 연금에 대한 소비가 크다는 것을 알 수 있다. 위쪽으로 갈수록 생활자금 소비가 크다. 인자 점수 그림을 보면, 세금과 공과, 대출의 소비금액이 크면서 생활자금 소비가 큰 연령층은 30대와 40대로 집계되며, 생활자금이 작으면서 연금소비와 저축액이 큰 연령층은 50대부터 70대, 생활자금의 소비가 크며 연금소비와 저축이 적으며 세금과 공과, 대출에 대한 소비가 적은 연령은 10대와 20대로 해석된다.

1번, 3번 공동인자의 인자적재그림에서는 위로 갈수록 공과에 대한 소비가 크고, 오른쪽으로 갈수록 세금에 대한 소비와 저축액이 크며, 연금소비와 대출액이 큰 집단이

모여 있을 것이다. 인자점수그림을 보면, 공과에 대한 소비가 큰 연령대는 10대와 40대부터 70대로 나타나며, 세금에 대한 소비, 저축액, 연금소비, 대출액이 큰 집단은 30대부터 70대 까지인 것으로 나타난다. 20대는 공과에 대한 소비가 작고, 세금, 연금소비가 적으며, 저축액, 대출액도 적은 것으로 나타난다.

2번, 3번 공동인자의 인자적재그림에서는 위쪽으로 갈수록 공과에 대한 소비가 크고, 오른쪽으로 갈수록 생활자금과 세금에 대한 소비와 대출액이 크며, 왼쪽으로 갈수록 연금소비와 저축액이 큰 것으로 나타난다. 이 때, 인자 적재 그림을 확인하면, 공과에 대한 소비가 크면서 생활자금에 대한 소비가 큰 집단은 10대, 연금소비와 저축액이 큰 집단은 60대와 70대, 세금에 대한 소비와 대출액이 큰 집단은 30대와 40대가 특징적으로 나타난다.

모든 것을 종합하여 해석하면, 10대는 공과에 대한 소비가 크면서 생활자금에 대한 소비가 큰 집단이라는 것을 알 수 있다. 20대는 공과에 대한 소비가 적지만, 생활자금에 대한 소비는 크다. 즉, 공과가 10대와 20대의 차이점을 확연하게 드러내준다고 이야기할 수 있다. 30대와 40대는 생활자금 소비가 크면서 대출액이 큰 집단으로 파악된다. 50대부터 70대까지는 생활자금에 대한 소비가 적고 연금소비와 저축액이 큰 연령층으로 파악된다.

이 때 이런 모든 특징을 합한 그래프를 그려보기 위해서 특이값 분해를 통한 인자행렬도를 그리면 그 결과는 아래와 같다. 또한 더 정확한 분석을 위해서 Varimax인자회전을 진행시켰다. 이는 그림 4.4.에서 확인가능하다.

iii. MLFA

MLFA를 시행하기 위해서는 다변량 정규성이 먼저 만족되어야 한다. 하지만, 위에서 보았듯이, raw data는 다변량 정규성을 만족하지 못한다는 사실을 안다. 하지만, PCA를 통하여 주성분 점수행렬 데이터에 대한 정규성 검정을 실시하였을 때 역시 다변량 정규성을 따르지 않는다는 사실을 알지만, 3번, 5번 변수에서 일변량 정규성을 따른다는 사실을 알 수 있기에, MLFA를 시행해볼 가치는 있다고 앞에서 이야기 하였다. (2. Data Description, i. 다변량 정규성 파악) 이에 의거하여 차원 축소된 행렬에 대해 MLFA를 진행한다.

MLFA를 진행하여 총 기여율을 확인하면, 그 결과는 표 4.2와 같다.

	설명비율
공동인자 1	4.1%
공동인자 2	1.6%
공동인자 3	0.8%

표 4.2. 총 기여율

MLFA에 대한 가능성을 확인하기 위해 총 기여율을 확인해보았지만, 총 기여율이 6.6%밖에 되지 않는다는 사실을 알 수 있다. 적어도 70%를 넘어야 분석이 가능한데, 이는 거의 분석을 할 수 없는 수준이라는

것을 알 수 있다. PCFA와 비교한 총 기여율은 표 4.3에서 확인할 수 있다.

	설명비율		설명비율
공동인자 1	38.91%	공동인자 1	4.1%
공동인자 2	23.22%	공동인자 2	1.6%
공동인자 3	17.10%	공동인자 3	0.8%
PCFA의 총 기여율		MLFA의 총 기여율	
표 4.3 총 기여율의 비교			

그러므로, 총 기여율의 관점에서 PCFA가 월등히 우월하다는 것을 안다. 그 후, 잔차 행렬을 비교하여, 어느 분석이 더 좋은 분석인지 확인해야한다. PCFA와 MLFA의 잔차행렬을 비교한 것은 표 4.4에서 확인 할 수 있다.

	utility.bills <dbl>	livingfund <dbl>	tax <dbl>	annualpension <dbl>	savings <dbl>	loan <dbl>
utility bills	0.000	-0.009	-0.178	0.009	-0.065	0.171
livingfund	-0.009	0.000	-0.121	0.053	0.095	-0.103
tax	-0.178	-0.121	0.000	-0.002	-0.053	-0.172
annualpension	0.009	0.053	-0.002	0.000	-0.060	-0.072
savings	-0.065	0.095	-0.053	-0.060	0.000	-0.084
loan	0.171	-0.103	-0.172	-0.072	-0.084	0.000

PCFA에 의한 잔차행렬

	utility.bills <dbl>	livingfund <dbl>	tax <dbl>	annualpension <dbl>	savings <dbl>	loan <dbl>
utility bills	-0.852	-0.077	-0.434	-0.037	-0.370	0.120
livingfund	-0.077	-0.845	-0.467	0.253	0.165	-0.409
tax	-0.434	-0.467	-0.618	-0.274	-0.415	-0.453
annualpension	-0.037	0.253	-0.274	-0.800	-0.780	-0.493
savings	-0.370	0.165	-0.415	-0.780	-0.582	-0.395
loan	0.120	-0.409	-0.453	-0.493	-0.395	-0.667

MLFA에 의한 잔차행렬

표 4.4. 잔차행렬 비교


잔차행렬의 원소들이 0으로 수렴해야 성능이 좋다고 판단할 수 있다. 이 때, PCFA의 대부분의 원소들은 0에 수렴하지만, MLFA의 원소들은 0에 수렴하는 원소들이 거의 없고, 심지어 거의 1에 가까운 값들을 가지고 있는 원소들도 많다. 잔차행렬을 보았을 때 PCFA의 성능은 MLFA의 성능보다 월등히 뛰어나다는 것을 알 수 있고, MLFA의 성능은 전혀 뛰어나지 않음을 사시하고 있다.

그러므로, MLFA를 시행할 이유가 전혀 없다는 것을 알 수 있다. 이는 설명력이 6.6%밖에 되지 않을뿐더러, 잔차행렬또한 1에 매우 가깝기 때문에 성능이 아주 나쁘기 때문이다.

5. Cluster Analysis (CA)

i. 계층적 군집분석

군집분석에는 여러 가지 연결법이 존재하는데, 이를 크게 두 부류로 나누면 계층적 연결법과 비 계층적 연결법이다. 이 때 모든 연결법은 표준화 유클리드 거리와 마할라노비스 거리를 이용하였다. 계층적 연결법은 단일연결법, 완전연결법, 평균연결법, 와드연결법이 존재한다. 이 때, 가장 대중화된 단일연결법과 와드연결법을 사용하기로 한다. 비 계층적 연결법에는 K-평균법과 K-중위수법이 존재하는데, 여기에서, 가장 많이 사용하는 K-연결법을 사용하기로 한다. 단일 연결법을 시행한 결과는 그림 5.1에 있다.



단일 연결법을 사용할 때, 60대와 70대는 각각의 군집을 형성하는 것을 알 수 있고, 30대와 40대는 같은 하나의 군집을 형성하며, 50대 또한 하나의 군집을, 20대와 10대도 하나의 군집을 형성하는 것을 알 수 있다. 하지만, 그 외에 관측치들이 난잡하게 섞여있는 것을 봐서, 군집이 확실하게 이루어 지지는 않았다고 할 수 있다.

반면, 와드 연결법을 사용하면, 10대와 20대가 하나의 군집으로 묶이는 것을 확인할 수 있으며, 60대와 70대가 하나의 군집으로, 40대부터 50대까지가 또 하나의 군집으로 묶이고, 30~50대까지, 20대~40대까지 각각 한 군집으로 묶인다. 하지만, 지역에 따라 사뭇 다른 관측치들이 관찰되며, 연령별로 나누어 지는 것 뿐만 아니라, 지역에 따라서도 군집이 나누어지고 있다는 것을 알 수 있다.

다음으로, 마할라노비스 거리를 이용하여 단일 연결법, 와드 연결법을 실시하였고, 그에 대한 결과는 그림 5.2.에 제시되어 있다.

단일 연결법에서는 유클리드 거리를 사용한 단일연결법과 마찬가지로 군집형성이 잘 안되어있다는 것을 확인할 수 있는데, 60대와 70대는 각각의 군집을 형성하는 것을 알 수 있고, 20대 또한 하나의 군집을 형성하는 것을 알 수 있다. 하지만, 10대의 군집에서 다른 연령층이 난잡하게 섞여있고, 30, 40, 50대 또한 난잡하게 섞여있는 것을 알 수 있다. 단일연결법에서는 군집분석이 제대로 이루어지지 않았다는 것을 확인할 수 있다.


와드 연결법을 사용하였을때는 10대와 20대가 한 군집을, 60대와 70대가 한 군집을, 40대, 50대가 한 군집을 이루고 30, 40, 50대가 한 군집을, 마지막으로 20대, 30대, 40대가 한 군집을 이루는 것도 맨 오른쪽에서 확인할 수 있는데, 이는 어느 지역의 20대는 30대, 40대와 비슷한 특성을 갖는다는 것을 짐작해볼 수 있다.

결국 단일연결법으로는 군집을 나누는 것이 불가능에 가깝고, 와드 연결법을 이용해서 군집을 나누는 것이 효과적이라는 사실을 파악하였다. 그렇기 때문에, 와드 연결법에 대한 결과를 나타내면 표 5.1과 같을 것이다.


	그룹 1	그룹 2	그룹 3	그룹 4	그룹 5
와드 연결법 with 표 준화 유클리드 거리	10, 20대	60,70대	40~50대	30~50대	20~40대
와드 연결법 with 마 할라노비스 거리	10, 20대	60,70대	40~50대	30~50대	20~40대

표 5.1. 와드 연결법에 대한 결과

결국 군집은 5개 정도로 나누는 것이 적절하다고 판단된다.




마할라노비스 거리를 이용한 단일 연결법



마할라노비스 거리를 이용한 와드 연결법

그림 5.2. 마할라노비스 거리를 이용한 단일 연결법과 와드 연결법

하지만, 군집수를 추정하기 위한 더 좋은 방법은, ccc와 Dindex등을 이용하는 것이다. 이에 대한 결과는 그림 5.3에 있다. 비록 표준화 유클리드 거리와 마할라노비스 거리를 이용하여 군집을 5개정도 형성할 수 있을 것이라고 유추해볼 수 있지만, 더 확실하게 파악하기 위해서는 여러 측도들을 사용해야 한다.



우선 ccc를 이용하여 군집의 수를 추정할 때는 ccc값이 가장 큰 경우의 군집수를 사용하면 되는데, 이 때, ccc가 가장 큰 값은 군집의 수가 7개 일 때이다. Dindex 그래프의 경우 기울기가 급격히 감소하는 구간(빨간 선 그래프), 기울기가 급격히 증가하는 구간(파란 선 그래프)로 군집의 수를 선택하는데, 이 때, 급격히 감소하는 구간은 군집의 수가 6인 구간이라고 할 수 있다. 즉, ccc와 Dindex에서는 군집이 6~7개 일 때 가장 좋은 분석이 된다고 판단하고 있다.

이 때, 모든 측도들을 사용하여 평가한 결과는 아래의 표 5.2에서 확인할 수 있다.

★ Among all indices: ★ 8 proposed 2 as the best number of clusters ★ 2 proposed 3 as the best number of clusters ★ 1 proposed 4 as the best number of clusters ★ 1 proposed 5 as the best number of clusters ★ 3 proposed 6 as the best number of clusters ★ 7 proposed 7 as the best number of clusters ★ 1 proposed 8 as the best number of clusters ★★★★★ conclusion ★★★★★
표 5.2. 모든 측도를 활용한 군집의 수 결정

이 때, 8개의 측도에서 2개의 군집으로 나누는 것이 가장 좋다고 이야기하였으며, 그 다음은 7개의 군집으로 나누는 것이 가장 좋은 분석이라고 평가하고 있다. 워드 연결법에서 군집을 5개로 나누었을 때 명확하게 나누어지지 않았던 관측치들이 7개의 군

집으로 나누면 더 명확히 구분된다는 것을 이야기해주고 있다.

ii. 비계층적 군집분석

계층적 연결법에서, 군집을 7개로 나누는 것이 가장 효과적이라고 판단하였다. (물론, 2개의 군집으로 나눈 것이 가장 효율적이라는 결과를 얻었지만, 2개로 나누었을 때 관측치들의 특성이 전혀 나타나지 않으므로, 2번째로 효율이 좋은 7개의 군집으로 나누는 방법을 사용한다.) 이 때, K-평균법을 사용하여 군집을 나누어주면 표 5.3과 같은 결과를 얻는다.

	관측치
그룹 1	10대 광주, 10대 대전, 10대 세종
그룹 2	10대 경남, 10대 대구, 10대 인천, 10대 전남 20대 전체 30대 경남, 30대 대전, 30대 울산
그룹 3	10대 제주 세종, 제주 제외 60대 전체 70대 전체
그룹 4	30대 서울 40대 서울, 40대 세종 50대 서울, 50대 세종, 50대 제주
그룹 5	10대 강원, 10대 경기, 10대 경북, 10대 부산 10대 서울, 10대 울산, 10대 전북, 10대 충남, 10대 충북
그룹 6	30대 강원, 30대 경북, 30대 전남, 30대 전북, 30대 충북 40대 강원, 40대 경남, 40대 경북, 40대 광주, 40대 전남, 40대 전북, 40대 충남, 40대 충북 50대 강원, 50대 경기, 50대 경남, 50대 경북, 50대 광주, 50대 울산, 50대 전남, 50대 전북, 50대 충남, 50대 충북
그룹 7	30대 경기, 30대 광주, 30대 대구, 30대 부산, 30대 세종, 30대 인천, 30대 제주, 30대 충남 40대 경기, 40대 대구, 40대 대전, 40대 부산, 40대 울산, 40대 인천, 40대 제주 50대 대구, 50대 대전, 50대 부산, 50대 인천 60대 세종, 60대 제주
표 5.3. K-평균법 결과	

또한, 각 군집에 대한 특성을 나타낸 표는 표 5.4에서 확인할 수 있다.

Group.1 <int>	utility.bills <dbl>	livingfund <dbl>	tax <dbl>	annualpension <dbl>	savings <dbl>	loan <dbl>
1	36212.00	11300.00	26486.67	118872.67	4367183	0
2	34658.67	46331.29	164012.38	98004.42	5791664	12299608
3	43527.18	36695.15	176063.03	139599.82	18550283	9314605
4	43794.83	48106.33	196755.00	150147.00	21678059	68699607
5	47621.89	44671.67	187461.00	55513.33	3269142	0
6	46918.70	46974.96	195818.39	135653.00	15802394	18813660
7	41245.43	46231.48	189287.10	144126.00	14675334	34902403

표 5.4. 각 군집에 대한 특성

6. 결론

이러한 분석이 우리에게 시사하는 바는 무엇인가. 우선 각 군집에 대한 특성을 파악하는 것이 우선일 것이다. 우선 10대들이 분포한 그룹을 파악하여 보자. 10대 광주, 10대 대전, 10대 세종은 그룹 1에, 10대 경남, 10대 대구, 10대 인천, 10대 전남은 그룹 2에, 10대 제주는 그룹 3에 10대 강원, 10대 경기, 10대 경북, 10대 부산, 10대 서울, 10대 울산, 10대 전북, 10대 충남, 10대 충북은 그룹 5에 위치해있고, 이를 쉽게 나타내기 위해서 표 6.1.에 정리하였다.

그룹 1	10대 광주, 10대 대전, 10대 세종
그룹 2	10대 경남, 10대 대구, 10대 인천, 10대 전남
그룹 3	10대 제주
그룹 5	10대 강원, 10대 경기, 10대 경북, 10대 부산
	10대 서울, 10대 울산, 10대 전북, 10대 충남, 10대 충북
표 6.1. 10대들의 분류	

그룹 1과 그룹 5에는 10대들만 위치해 있고, 그룹 2에는 20대들이 주를 이루며, 그룹 3에는 60대와 70대가 주를 이룬다는 것을 알 수 있다. 그룹 1은 다른 그룹들보다 생활자금 소비액이 적고, 그룹 5에 비해서 저축하는 돈이 많으며, 연금소비액이 크다. 이 말의 의미는, 광주, 대전, 세종에 사는 10대들은 다른 10대들보다 생활자금을 적게 쓰면서 절약을 하고, 미래를 위해서 저축하고, 심지어 연금(보통 부모들이 자녀들을 위해 가입하는 경우가 많을 것이다.)까지 고려하는 것을 알 수 있다. 즉, 다른 10대들보다 광주, 대전, 세종에 사는 10대들이 절약을 하며 미래를 위한 대비를 철저히 한다고 할 수 있다.

그룹 2는 20대가 대부분을 차지하고, 그들의 특성은 10대들보다 생활자금 소비액이 많으며, 연금이나 저축을 거의 하지 않는다는 것이 특징이다. 다른 10대들보다 저축을 많이 하지만, (빠르면 20대 초반, 느리면 20대 중, 후반에 직장인이 되는 경우가 많으므로) 생활자금 소비액이 많고 연금에 대한 대비를 안하는 것으로 볼 때, 상대적으로 미래에 대한 대비를 하지 않으면서 현재 지출이 큰 10대들이라고 할 수 있다. 즉, 경남과 대구, 인천과 전남에 사는 10대들은 미래에 대한 대비를 거의 하지 않으며, 현재에 돈을 많이 쓰는 사람들이라고 할 수 있을 것이다.

그룹 3는 주로 노년층이 주를 이루고 있으며, 연금과 저축에 대한 대비가 투철하고, 그룹 1보다는 생활자금 소비액이 많지만, 그룹 5에 비해서 생활자금 소비액이 적은 것이 특징이다. 이는 제주도의 특수성 때문에 일어나는 일이다. 제주도는 노년 인구가 많기 때문에, 10대들의 소비패턴에도 노인들의 영향을 크게 받을 것이고, 그 결과 소비는 노년인구만큼 하면서 미래를 위한 준비를 투철하게 한다고 할 수 있다. 그룹 1에 있는 광주, 대전, 세종에 있는 10대들보다 더 많은 소비를 하지만, 노년 인구의 영

향을 받아서 미래도 많이 준비한다는 사실도 안다.

마지막으로 그룹 5는 대부분의 10대들의 특징을 나타낸다고 할 수 있는데, 저축과 연금에 대해 전혀 신경 쓰지 않으며, 생활자금 소비도 많은 것이 특징이다.

이를 정리한 것이 표 6.1.1에 존재한다.

소비를 적게 하며 미래를 준비함	10대 광주, 10대 대전, 10대 세종
소비를 많이 하며 미래를 어느 정도 준비함	10대 경남, 10대 대구, 10대 인천, 10대 전남
소비를 적당히 하며 미래에 대한 대비를 많이 함	10대 제주
소비를 많이 하고 미래에 대한 대비를 안 함	10대 강원, 10대 경기, 10대 경북, 10대 부산 10대 서울, 10대 울산, 10대 전북, 10대 충남, 10대 충북
표 6.1.1 10대들의 특징	

20대들은 그룹 2에 모두 존재하며, 이들의 특징은 소비를 많이 하고, 다른 30대부터 70대의 연령층보다 미래에 대한 대비를 안 하는 것이 특징이다. 이는 모든 지역에서 공통적으로 나타나는 특성으로, 20대들은 소비를 중시하고, 미래에 대한 준비는 별로 하지 않는 것이 특징이다.

30대의 경우, 그룹 2, 그룹 4, 그룹 6, 그룹 7에 존재하며, 이를 정리한 것이 표 6.2.와 같다.

그룹 2	30대 경남, 30대 대전, 30대 울산
그룹 4	30대 서울
그룹 6	30대 강원, 30대 경북, 30대 전남, 30대 전북, 30대 충북
그룹 7	30대 경기, 30대 광주, 30대 대구, 30대 부산, 30대 세종, 30대 인천, 30대 제주, 30대 충남
표 6.2. 30대들의 분류	

이 때, 그룹 2는 20대들이 주를 이루는 것이 특징이다. 30대 임에도 불구하고, 아직까지 소비를 중시하는 지역은 경남, 대전, 울산이라는 것을 알 수 있다. 그들은 30대가 들어섰지만, 아직까지 20대의 소비력을 가지고 있다. 그러므로 다른 30대의 사람들보다 저축을 하는 사람들이 매우 적다.

그룹 4같은 경우 현재 우리나라의 부동산 문제를 여실히 보여주고 있다는 것이 느껴진다. 그룹 4의 특징은 바로 대출소비액이 다른 어떤 그룹보다 최대 6배, 최소 2배정도 크다는 것이다. 서울의 부동산 문제로 인해 대출을 받는 사람들이 많고, 그러한 대출을 많이 받는 사람들이 서울에 몰려있다는 것을 알 수 있다. 또한 세금 소비액도

굉장히 높다는 것을 확인할 수 있는데, 이는 각종 부동산에 따른 세금일수도 있고, 수입에 대한 세금일 수도 있다. 즉, 서울의 30대는 30대 중 돈을 가장 많이 벌며, 대출도 많이 한다는 것을 알 수 있다. 그로 인해서 미래에 대한 대비가 투철하고, 30대 중 저축을 가장 많이 한다는 것을 알 수 있다.

그룹 6는 모든 변수들의 값이 다른 그룹과 비교했을 때 평이하다는 사실을 알 수 있다. 즉, 기본적인 30대의 특징이라는 것을 알 수 있다. 다만, 대출이 소비를 중시하는 그룹 2보다는 많지만, 다른 그룹들에 비해서는 한없이 적다는 것을 보여주고 있고, 이는 그룹 6에 있는 사람들이 대출을 하는 일이 거의 없다는 것을 설명해준다. 그룹 6에 속하는 지역은 강원, 경북, 전남, 전북, 충북지역으로 부동산 값이 낮은 광역시가 아닌 지역이다. 즉, 지역의 특수성이 그들의 대출사용 저하를 불러일으킨 것이다.

이에 반해 그룹 7은 서울에 이어서 2번째로 대출에 돈을 많이 쓰는 지역으로, 여기 있는 지역들은 충남을 제외한 모든 곳이 광역시임을 알 수 있다. 그룹 6와는 다르게, 광역시는 부동산 값이 광역시가 아닌 지역보다 높으므로, 대출을 더 많이 사용하는 것을 알 수 있다. 이러한 특성을 정리한 표는 표 6.2.1에 있다.

20대의 소비력을 가지고 미래에 대한 준비를 거의 하지 않는 지역	30대 경남, 30대 대전, 30대 울산
대출을 많이하고 그에 따른 미래에 대한 준비를 많이 하는 지역	30대 서울
대출을 많이 하지 않는 광역시가 아닌 지방 미래에 대한 준비는 어느정도 하는 지역	30대 강원, 30대 경북, 30대 전남, 30대 전북, 30대 충북
광역시가 아닌 지역보다 대출을 많이 해야하는 광역시	30대 경기, 30대 광주, 30대 대구, 30대 부산, 30대 세종,
미래에 대한 준비는 어느정도 하는 지역	30대 인천, 30대 제주, 30대 충남
표 6.2.1 30대들의 특징	

40대들은 그룹 4, 그룹 6, 그룹 7에 위치하며, 이를 명료하게 표로 정리한 것이 표 6.3이다.

그룹 4	40대 서울, 40대 세종
그룹 6	40대 강원, 40대 경남, 40대 경북, 40대 광주, 40대 전남, 40대 전북, 40대 충남, 40대 충북
그룹 7	40대 경기, 40대 대구, 40대 대전, 40대 부산, 40대 울산, 40대 인천, 40대 제주
표 6.3. 40대들의 분류	

40대에 20대처럼 행동하는 사람들은 없다는 것이 표 6.2.가 보여주고 있다. 30대 때 20대처럼 행동하던 경남, 대전, 울산의 사람들이 경남은 그룹 6에, 대전과 울산은 그룹 7에 편입된 모습을 보여준다. 이는 그들이 지방에 따른 특수성을 제외하면, 그 연

령에 맞는 가계자금 소비를 하고 금융자산을 가지고 있다는 표현과 일치한다. 여기에 특별한 관측치는 세종에 사는 40대인데, 세종에 사는 40대는 서울에 사는 40대처럼 행동하는 것을 볼 수 있다. 즉, 대출을 많이 하고 그에 따른 미래에 대한 준비도 많이 한다는 것인데, 이는 40대들이 서울에서 생활하는 것과 세종에서 생활하는 것이 체감상 비슷하다는 것을 유추해볼 수 있는 부분이다. 이를 잘 정리한 것은 표 6.3.1에 존재한다.

대출을 많이하고 그에 따른 미래에 대한 준비를 많이 하는 지역	40대 서울, 40대 세종
대출을 많이 하지 않는 광역시가 아닌 지방 미래에 대한 준비는 어느정도 하는 지역	40대 강원, 40대 경남, 40대 경북, 40대 광주, 40대 전남, 40대 전북, 40대 충남, 40대 충북
광역시가 아닌 지역보다 대출을 많이 해야하는 광역시 미래에 대한 준비는 어느정도 하는 지역	40대 경기, 40대 대구, 40대 대전, 40대 부산, 40대 울산, 40대 인천, 40대 제주
표 6.3.1 30대들의 특징	

30대, 40대에서 이상하게 느끼는 점은 바로 광주광역시와 제주도 지역이다. 광주광역시는 광역시가 아닌 지방이 아닌데 광역시가 아닌 지방의 그룹에 속하여있고, 제주도는 광역시가 아닌데 광역시의 그룹에 속해있다. 이는 광주광역시가 광역시 정도의 생활수준을 요구하지 않고, 광역시가 아닌 지방정도의 생활수준을 요구한다는 것을 알 수 있으며, 반면 제주도는 광역시가 아닌 지역임에도 불구하고 광역시 정도의 생활수준을 가지고 있어야 된다는 것을 시사한다.

정리하면, 40대는 자신의 지역에 맞는 가계자금 소비와 금융자산을 보유하고 있고, 경제적 안정기에 접어들었음을 시사한다.

50대는 그룹 4, 그룹 6, 그룹 7에 속해있다. 이를 간단히 표로 나타낸 것이 표 6.4에 존재한다.

그룹 4	50대 서울, 50대 세종, 50대 제주
그룹 6	50대 강원, 50대 경기, 50대 경남, 50대 경북, 50대 광주, 50대 울산, 50대 전남, 50대 전북, 50대 충남, 50대 충북
그룹 7	50대 대구, 50대 대전, 50대 부산, 50대 인천
표 6.4. 50대들의 분류	

이 때, 광역시가 아닌 지역임에도 불구하고 광역시 정도의 생활수준을 가지고 있어야 되는 제주는 50대의 연령층에 이르러 서울 수준의 생활수준을 가지고 있어야 살 수 있는 곳이 되었다는 것을 알 수 있다. 즉, 제주도에 사는 사람들은 연령이 증가함에 따라 계속해서 대출이 증가한다는 것을 알 수 있고, 그에 따른 저축도 지속해서 늘어난다는 사실을 알 수 있다.

이와 반면에, 경기, 울산같은 경우, 오히려 대출이 줄어들고 안정되었다는 사실을 알 수 있다. 즉, 경기와 울산은 연령이 높아지고, 자산이 축적되면 오히려 안정적인 생활이 가능하다고 유추할 수 있다. 이에 대해 정리한 것은 표 6.4.1에 있다.

높은 대출과 저축, 높은 생활 수준을 요구하는 지역	50대 서울, 50대 세종, 50대 제주
안정된 생활수준을 가진 지역	50대 강원, 50대 경기, 50대 경남, 50대 경북, 50대 광주, 50대 울산, 50대 전남, 50대 전북, 50대 충남, 50대 충북
안정된 지역보다는 높은 생활 수준을 요구하는 지역	50대 대구, 50대 대전, 50대 부산, 50대 인천
표 6.4.1 50대들의 특징	

60대는 그룹 3과 그룹 7에 존재하는데, 이를 표로 명료하게 나타낸 것이 표 6.5에 존재한다.

그룹 3	세종, 제주 제외 60대 전체
그룹 7	60대 세종, 60대 제주
표 6.4. 50대들의 분류	

이 때, 그룹 3은 대출이 가장 낮은 그룹이고, 그룹 7은 대출이 가장 높은 지역임을 표 5.4에서 알 수 있다. 이는 세종과 제주를 제외한 모든 60대들은 대출을 갚아나가는 안정기에 접어든 반면, 세종과 제주는 아직도 대출액이 많다는 것을 알 수 있다. 이는 서울에 사는 사람들은 수입이 많아서 대출액을 빨리 갚아 나갈 수 있었던 반면, 제주와 세종은 그 정도의 수입은 미치지 못하여 대출액을 갚아나가지 못하고 있는 상황을 의미한다.

70대는 저축액이 가장 많고 연금에 대한 소비가 가장 많은 그룹 3에 위치하여, 노년을 준비하는 모습을 여실히 보여준다.

이러한 분석은 분명 2020년 12월 말에 연령별, 지역별로 조사한 자료이지만, 어느 정도의 지역에 따른 가계소비와 금융자산에 대한 사이클이 존재한다는 것을 시사해준다. 또한, 광역시 인지 아닌지, 서울인지 아닌지에 따라서 그들의 가계소비와 금융자산에 대한 특징이 서로 다르고, 그들의 연령에 따라서도 선명한 특징을 보인다는 것을 알 수 있다.

B. 동학개미운동을 통한 지역/연령별 투자 전략을 이해하기 위한 다변량 자료 분석

1. Data

i. 전반적인 데이터 설명

“[2021금융데이터경진대회] 동학개미운동 신규 고객 투자 정보“ 데이터는 한국투자증권에서 제공한 데이터 자료로써, 연령별로는 20대, 30대, 40대, 50대로 나누고, 대한민국의 지역을 총 16개로 분류 (강원, 경기, 경남, 경북, 광주, 대구, 대전, 부산, 서울, 울산, 인천, 전남, 전북, 제주, 충남, 충북, 총 8도, 1 특별자치도, 1특별광역시, 6광역시)하여, 2020년 동학개미운동이 일어난 시점을 기준으로 고객 구분 코드, 고객 성별 구분 코드, 동일 나이군 구분 코드, 주소(시,도), 주문일자, 주문시간대, 상품번호, 상품명, 거래소구분코드, 매도매수구분코드, 주문 구분코드, 실 주문단가, 주문수량, 총 체결수량, 총 체결금액, 전일종가, 당일시가, 일종고가, 일종저가, 당일종가, 거래수량, 거래대금, 상한가 여부, 하한가 여부를 조사한 데이터이다.

ii. Tidy Data

전체적인 모든 것을 조사할 수 없으므로, 데이터를 필요한 부분만 간소화 시켰다. 우리는 앞의 데이터인 지역 및 연령별 10대소비(가계자금) 금액 및 금융자산 데이터에 관심이 있으므로 이 것과 관계있는 변수들만 남기기로 하고, 나머지 변수들은 제거하기로 하였다. 즉, 고객 구분 코드, 고객 성별 구분 코드, 주문일자, 주문시간대, 상품번호, 상품명, 거래소구분코드, 매도매수구분코드, 주문 구분코드, 상한가 여부, 하한가 여부를 제거하여 데이터를 간소화시켰다. 그 후, 845941개의 데이터를 요약하기 위해서 중앙값을 사용하여 정제하였다. 평균을 쓰지 않고 중앙값을 사용한 이유는, 데이터의 표준편차가 매우 크기 때문에 평균으로는 데이터의 집단적 특성을 드러내기 어렵기 때문이다.

iii. 관측치에 대한 설명

이 때, 연령대와 시도명의 경우, 데이터분석을 용이하게 하기 위해서 1~119까지의 숫자로 라벨링하였다. 그 내역은 아래와 같다.

obs	연령대	obs	시도명	obs	시도명	obs	시도명	obs	시도명
200	20대	1	강원	5	광주	9	서울	13	전북
300	30대	2	경기	6	대구	10	울산	14	제주
400	40대	3	경남	7	대전	11	인천	15	충남
500	50대	4	경북	8	부산	12	전남	16	충북

즉, 백의 자리 수는 연령대를 나타내고, 십의자리, 일의자리는 시도를 나타낸다고 할 수 있다.

iv 변수에 대한 설명

실주문단가	실주문 단가는 매수 혹은 매도 주문이 접수된 종목의 단가이다.
주문수량	주문수량은 매수 혹은 매도 주문이 접수된 종목의 수량이다.
총체결수량	총 체결 수량은 주문수량 중에서 실제로 체결된 수량이다.
총체결금액	총 체결 금액은 총 체결수량과 체결 평균 단가를 곱한 값이다.
전일종가	전일종가는 주식시장에서 전날 마지막 거래가격을 의미한다.
당일시가	당일시가는 주식시장에서 현재 거래되는 주식의 가격을 의미한다
일종고가	일종고가는 당일 주식시장 마감되기 전까지 가장 높은 가격을 의미한다
일종저가	일종저가는 당일 주식시장이 마감되기 전까지 가장 낮은 가격을 의미한다
당일종가	당일종가는 주식시장에서 당일 마지막 거래가격을 의미한다.
거래수량	거래수량은 주식시장에서 거래된 주식의 총수량을 의미한다.
거래대금	거래대금은 주식시장에서 거래된 주식의 총수량에 주가가격을 곱한 것을 의미한다.

이 때, 이 자료를 수치적으로 요약한 것은 그림 6.1과 같다.


실주문단가	주문수량	총체결수량	총체결금액
Min. : 5410	Min. : 7.00	Min. : 7.00	Min. : 96250
1st Qu.: 9530	1st Qu.: 10.00	1st Qu.: 10.00	1st Qu.: 143944
Median :12000	Median : 11.00	Median : 10.50	Median : 199800
Mean :12430	Mean : 26.02	Mean : 24.31	Mean : 280109
3rd Qu.:14712	3rd Qu.: 18.25	3rd Qu.: 18.25	3rd Qu.: 310688
Max. :26000	Max. :600.00	Max. :502.50	Max. :2177550
전일종가	당일시가	일종고가	일종저가
Min. : 4630	Min. : 1640	Min. : 5920	Min. : 4630
1st Qu.: 8825	1st Qu.: 9025	1st Qu.:10072	1st Qu.: 8535
Median :10875	Median :11150	Median :12600	Median :10525
Mean :11647	Mean :11778	Mean :13154	Mean :11163
3rd Qu.:13700	3rd Qu.:14012	3rd Qu.:15762	3rd Qu.:12831
Max. :25650	Max. :25600	Max. :26700	Max. :24500
당일종가	거래수량	거래대금	
Min. : 5190	Min. : 2294808	Min. :3.240e+10	
1st Qu.: 9165	1st Qu.: 4017082	1st Qu.:5.795e+10	
Median :11675	Median : 5772108	Median :6.685e+10	
Mean :12135	Mean : 5695796	Mean :6.488e+10	
3rd Qu.:14288	3rd Qu.: 6807537	3rd Qu.:7.450e+10	
Max. :25300	Max. :15335287	Max. :8.660e+10	

표 1.1. 자료의 수치적 요약

2. Data Description

i. 원본 데이터 특성 파악

우리의 목표는 연령별, 지역별 투자의 성향에 대해 알고 싶은 것이므로, 변수들 간의 상관성을 파악하기 위해서 Scatter Plot을 사용할 것이다. 이 결과는 그림 6.2에 나타나있다.



또한, 이를 더 수치적으로 파악하기 위해서 상관행렬을 고려해볼 수도 있다. 이 결과는 표 7.1에서 볼 수 있다.

	실주문단가	주문수량	총체결수량	총체결금액
실주문단가	1.000000000	-0.23108898	-0.231171022	-0.004449222
주문수량	-0.231088983	1.000000000	0.999309074	0.917929996
총체결수량	-0.231171022	0.99930907	1.000000000	0.927741528
총체결금액	-0.004449222	0.91793000	0.927741528	1.000000000
전일종가	0.997609309	-0.23226654	-0.231850613	-0.001889785
당일시가	0.890734721	-0.22502227	-0.226546812	-0.036851508
일중고가	0.998574568	-0.23055345	-0.230908606	-0.004742898
일중저가	0.996778041	-0.23041528	-0.230682461	-0.006152956
당일종가	0.997928757	-0.23223469	-0.232498689	-0.008779181
거래수량	-0.739206826	0.48885533	0.475379182	0.173255386
거래대금	-0.171217072	0.02338756	0.006123456	-0.184528802
	전일종가	당일시가	일중고가	일중저가
실주문단가	0.997609309	0.89073472	0.998574568	0.996778041
주문수량	-0.232266540	-0.22502227	-0.230553448	-0.230415282
총체결수량	-0.231850613	-0.22654681	-0.230908606	-0.230682461
총체결금액	-0.001889785	-0.03685151	-0.004742898	-0.006152956
전일종가	1.000000000	0.89472542	0.995762379	0.998320018
당일시가	0.894725422	1.000000000	0.890240777	0.889931247
일중고가	0.995762379	0.89024078	1.000000000	0.994668532
일중저가	0.998320018	0.88993125	0.994668532	1.000000000
당일종가	0.996370770	0.88683803	0.997885306	0.997118510
거래수량	-0.736843718	-0.65096269	-0.740057326	-0.728948666
거래대금	-0.175514510	-0.15701739	-0.160421853	-0.168491968
	당일종가	거래수량	거래대금	
실주문단가	0.997928757	-0.7392068	-0.171217072	
주문수량	-0.232234689	0.4888553	0.023387563	
총체결수량	-0.232498689	0.4753792	0.006123456	
총체결금액	-0.008779181	0.1732554	-0.184528802	
전일종가	0.996370770	-0.7368437	-0.175514510	
당일시가	0.886838030	-0.6509627	-0.157017386	
일중고가	0.997885306	-0.7400573	-0.160421853	
일중저가	0.997118510	-0.7289487	-0.168491968	
당일종가	1.000000000	-0.7370399	-0.163108639	
거래수량	-0.737039919	1.0000000	0.571458186	
거래대금	-0.163108639	0.5714582	1.000000000	

표 2.1. 상관행렬

이 때, 상관행렬에서 실주문단가와 전일종가, 당일시가 일중고가, 일중저가 당일종가는 강한 양의 상관관계를 보이고, 거래수량과는 강한 음의 상관관계를 보여준다고 할 수 있다. 또한, 주문수량과 총 체결수량, 총 체결금액은 강한 양의 상관관계를 보여주고, 거래수량과는 약한 양의 상관관계를 보여주는 것을 파악할 수 있다. 이렇게, 변수들 간의 특성이 서로 어느 정도의 상관관계를 가지고 있으므로, PCA나 FA같은 R-technique을 사용하여 새로운 변수를 찾아서 데이터를 분석하는 것이 가능하다고 파악된다. 또한, 상관행렬에서 데이터를 보았을 때 어느 정도의 군집을 이루고 있다고 할 수 있는데, 어떻게 군집을 이루고 있는지는 모르기 때문에, 변수에 특성에 따라서 CA와 같은 Q-technique를 시도해야한다. 그렇기 때문에 우리는 PCA, FA를 모두 사용하고, 그 방법들을 비교해보면서 최적의 분석방법을 찾아야 할 것이다.

ii. 다변량 정규성 파악

다변량 정규성에 대한 가정은 MLFA를 수행하는데 기본적으로 필요한 가정이다. 이 데이터가

다변량 정규성을 만족하지 않는다면, PCA나 PCFA를 통하여 분석을 실시하여야 하나, 만약 다변량 정규성을 만족한다면, MLFA로도 분석을 시행해 볼 수 있을 것이다. 이때, raw data를 놓고 보았을 때 굉장히 큰 편차를 보여주고, 변수간의 편차가 매우 심하기 때문에, 데이터를 log변환 하였다. 그 후, 다변량 정규성을 만족하는지 확인하기 위해서 mardia test를 시행하였고, 결과에 대한 qq-plot은 그림 2.2에, 정규성 검정의 수치적인 결과는 표 2.2에 정리되어 있다.

\$multivariateNormality						
	Test	Statistic	p value	Result		
1	Mardia skewness	1465.88042385362	1.55087268253054e-157	NO		
2	Mardia Kurtosis	22.7755706390833	0	NO		
3	MVN	<NA>	<NA>	NO		
\$univariateNormality						
	Test	Variable	Statistic	p value	Normality	
1	Anderson-Darling	실주문단가	0.3883	0.3762	YES	
2	Anderson-Darling	주문수량	5.6667	<0.001	NO	
3	Anderson-Darling	총체결수량	5.6779	<0.001	NO	
4	Anderson-Darling	총체결금액	0.8370	0.0293	NO	
5	Anderson-Darling	전일종가	0.3332	0.5045	YES	
6	Anderson-Darling	당일시가	1.0696	0.0077	NO	
7	Anderson-Darling	일종고가	0.4348	0.2914	YES	
8	Anderson-Darling	일종저가	0.3341	0.5034	YES	
9	Anderson-Darling	당일종가	0.3436	0.4783	YES	
10	Anderson-Darling	거래수량	0.9740	0.0133	NO	
11	Anderson-Darling	거래대금	1.3869	0.0012	NO	
\$Descriptives						
	n	Mean	Std.Dev	Median	Min	Max
실주문단가	64	9.383341	0.2987559	9.392737	8.596189	10.165890
주문수량	64	2.780261	0.6745972	2.484907	2.079442	6.398595
총체결수량	64	2.769728	0.6562905	2.441401	2.079442	6.221584
총체결금액	64	12.310055	0.6112305	12.205017	11.474715	14.593711
전일종가	64	9.314379	0.3111020	9.294184	8.440528	10.152338
당일시가	64	9.309687	0.3905968	9.319244	7.403061	10.150387
일종고가	64	9.441065	0.2956259	9.441500	8.686261	10.192456
일종저가	64	9.273065	0.3064456	9.261533	8.440528	10.106469
당일종가	64	9.357954	0.3034397	9.365105	8.554682	10.138599
거래수량	64	15.487600	0.3705118	15.568547	14.646160	16.545667
거래대금	64	24.875601	0.2106550	24.925703	24.201424	25.184566
	25th	75th	Skew	Kurtosis		
실주문단가	9.162298	9.596494	0.15783901	-0.21063877		
주문수량	2.397895	2.957262	2.91248929	11.41096455		
총체결수량	2.397895	2.957262	2.82418757	10.61745612		
총체결금액	11.877156	12.646390	1.01716725	1.45157112		
전일종가	9.085453	9.525204	0.16479192	0.09532496		
당일시가	9.107853	9.547775	-1.60916003	7.07278419		
일종고가	9.217652	9.665451	0.13194888	-0.37853329		
일종저가	9.052035	9.459716	0.22653842	0.08935970		
당일종가	9.123252	9.567200	0.14682058	-0.21636590		
거래수량	15.206060	15.733320	0.02246476	-0.33680626		
거래대금	24.782710	25.034022	-1.10036976	1.05801567		

표 2.2. raw data에 대한 정규성 검정의 수치적인 결과

표 2.2. raw data에 대한 정규성 검정의 수치적인 결과

이 때, 왜도와 첨도에서 모두 다변량 정규성을 가지지 않고, 11개의 변수 중 5개의 변수에서 일변량 정규성을 가진다는 사실을 알 수 있다. 이는 원론적으로는 다변량 정규성을 만족하지 않아 MLFA를 시행할 수 없다는 결론을 가진다.




그림 2.2. 주성분 점수행렬에 대한 정규성 검정의 수치적인 결과

3. Principal Component Analysis(PCA)

i. 공분산행렬과 상관행렬의 선택


PCA를 시작하기 전에, 데이터가 PCA 수행과정에서 상관행렬이 적합한지, 공분산행렬이 적합한지를 알아야한다. 이 때, 각 변수들의 단위를 알고, 서로의 공분산의 크기가 크게 차이가 나지 않는다면, 공분산 행렬을 사용하고, 단위를 모르고, 서로의 공분산의 크기가 크게 차이가 난다면, 상관행렬을 사용해야 한다. 이 때, “[2021금융데이터경진대회] 동학개미운동 신규 고객 투자 정보“ 데이터는 로그변환을 해 줌으로써 공분산 간의 차이가 크진 않지만, 변수의 단위가 ‘수량’과 ‘원(₩)’으로 서로 다르기에 상관행렬을 이용하여 PCA를 진행해야 한다는 사실을 안다.

	실주문단가	주문수량	총체결수량	총체결금액
실주문단가	0.08925509	-0.03442208	-0.03346208	0.04769377
주문수량	-0.03442208	0.45508140	0.44245564	0.36075187
총체결수량	-0.03346208	0.44245564	0.43071716	0.35102881
총체결금액	0.04769377	0.36075187	0.35102881	0.37360268
전일종가	0.09271492	-0.03775791	-0.03653668	0.04916669
당일시가	0.07974900	-0.05631828	-0.05556789	0.02432307
일종고가	0.08821371	-0.03370619	-0.03281933	0.04786443
일종저가	0.09131655	-0.03781123	-0.03669059	0.04738127
당일종가	0.09050727	-0.03644386	-0.03538199	0.04725687
거래수량	-0.09035862	-0.01658186	-0.01693582	-0.10352506
거래대금	-0.01175843	-0.04297530	-0.04269166	-0.05372889
	전일종가	당일시가	일종고가	일종저가
실주문단가	0.09271492	0.07974900	0.08821371	0.09131655
주문수량	-0.03775791	-0.05631828	-0.03370619	-0.03781123
총체결수량	-0.03653668	-0.05556789	-0.03281933	-0.03669059
총체결금액	0.04916669	0.02432307	0.04786443	0.04738127
전일종가	0.09678447	0.08356593	0.09161959	0.09517643
당일시가	0.08356593	0.15256587	0.07898709	0.08155427
일종고가	0.09161959	0.07898709	0.08739468	0.09022362
일종저가	0.09517643	0.08155427	0.09022362	0.09390891
당일종가	0.09411919	0.08051268	0.08952505	0.09278980
거래수량	-0.09508142	-0.07880853	-0.08871301	-0.09284721
거래대금	-0.01295637	-0.01246105	-0.01083551	-0.01217095
	당일종가	거래수량	거래대금	
실주문단가	0.09050727	-0.09035862	-0.01175843	
주문수량	-0.03644386	-0.01658186	-0.04297530	
총체결수량	-0.03538199	-0.01693582	-0.04269166	
총체결금액	0.04725687	-0.10352506	-0.05372889	
전일종가	0.09411919	-0.09508142	-0.01295637	
당일시가	0.08051268	-0.07880853	-0.01246105	
일종고가	0.08952505	-0.08871301	-0.01083551	
일종저가	0.09278980	-0.09284721	-0.01217095	
당일종가	0.09207564	-0.09143908	-0.01149956	
거래수량	-0.09143908	0.13727901	0.05058662	
거래대금	-0.01149956	0.05058662	0.04437554	

표 3.1. 공분산 행렬

ii. 주성분 개수의 선택

“[2021금융데이터경진대회] 동학개미운동 신규 고객 투자 정보“ 데이터는 총 11개의 변수로 이루어진 데이터이다. 이 변수들의 차원을 줄이기 위해 PCA를 실시하는데, 주성분의 개수를 구하는 방법에는 설명비율과, 이 설명비율을 시각적으로 볼 수 있는 Scree Plot이 존재한다. 설명비율에 대한 결과는 표 8.2에서, Scree Plot은 그림 7.1에서 확인할 수 있다.

<table> <tr> <th></th><th>설명비율</th></tr> <tr> <td>주성분 1</td><td>58.28</td></tr> <tr> <td>주성분 2</td><td>28.18</td></tr> <tr> <td>주성분 3</td><td>8.26</td></tr> <tr> <td>주성분 4</td><td>4.38</td></tr> <tr> <td>주성분 5</td><td>0.53</td></tr> <tr> <td>주성분 6</td><td>0.28</td></tr> <tr> <td>주성분 7</td><td>0.04</td></tr> <tr> <td>주성분 8</td><td>0.02</td></tr> <tr> <td>주성분 9</td><td>0.01</td></tr> <tr> <td>주성분 10</td><td>0.01</td></tr> <tr> <td>주성분 11</td><td>0.00</td></tr> </table>		설명비율	주성분 1	58.28	주성분 2	28.18	주성분 3	8.26	주성분 4	4.38	주성분 5	0.53	주성분 6	0.28	주성분 7	0.04	주성분 8	0.02	주성분 9	0.01	주성분 10	0.01	주성분 11	0.00	Scree Graph  The Scree Graph plots Eigenvalue (Y-axis, 0 to 6) against Component Number (X-axis, 1 to 11). The first component has an eigenvalue of approximately 5.8, the second is approximately 2.8, and the third is approximately 0.8. From the fourth component onwards, the eigenvalues drop significantly and remain very low, near zero.
	설명비율																								
주성분 1	58.28																								
주성분 2	28.18																								
주성분 3	8.26																								
주성분 4	4.38																								
주성분 5	0.53																								
주성분 6	0.28																								
주성분 7	0.04																								
주성분 8	0.02																								
주성분 9	0.01																								
주성분 10	0.01																								
주성분 11	0.00																								
표 3.2. 설명비율	그림 3.1. Scree Plot																								

이 때, 설명비율은 70%를 넘으면 주성분 분석을 실시할 수 있는데, 주성분 3개의 설명비율을 더하면 94.72%가 되므로, 주성분을 3개 사용하여 분석하는 것이 맞다. 또한, Scree Plot을 생각하면, 팔꿈치가 3번째 주성분에 있다는 것을 확인할 수 있으므로 3개의 주성분을 사용하는 것이 최적의 방법임을 알 수 있다.

iii. 주성분 해석

	PC1	PC2	PC3
x1	0.39	0.03	-0.11
x2	-0.05	-0.55	-0.20
x3	-0.05	-0.55	-0.19
x4	0.12	-0.52	-0.19
x5	0.39	0.03	-0.10
x6	0.29	0.08	-0.01
x7	0.39	0.03	-0.13
x8	0.39	0.04	-0.10
x9	0.39	0.04	-0.12
x10	-0.35	0.15	-0.35
x11	-0.12	0.29	-0.84

표 3.3. 주성분 계수

표 8.3은 주성분 계수를 나타내는 표이다.

이 때, 첫 번째 주성분을 보면, x2,x3에 해당하는 주문수량, 총체결수량, x10,x11에 해당하는 거래수량과 거래대금과는 음의 관계 나머지 변수와는 양의 관계이므로 위 네가지 변수를 제외하고 있으므로 제 1 주성분은 거래된 주식의 가격을 나타내는 성분으로 볼 수 있으며, 표 8.2에서 확일 할 수 있듯이 위 주성분의 설명력은 58.28%이다.

두 번째 주성분의 경우 변수 x2,x3,x4에 해당하는 주문수량, 총체결수량, 총체결금액 등에 크게 반응하고있음을 볼 수 있다. 즉 두 번째 주성분은 체결된 주식의 수량에 대한 정보를 반영하고 있다고 볼 수 있다. 이러한 두번째 주성분의 설명력은 28.18%이다.

세번째 주성분은 변수 x11에 대한 주성분 계수의 값이 유독 크다는 것을 확인할 수 있다. 이 변수는 거래대금을 반영하고 있다. 거래대금은 거래된 주식의 가격과 양의 정보를 모두 포함하는 변수이다. 일반적으로 거래대금의 절대적 크기가 클 수록 우량주에 속하므로, 주식의 안정성과 관련된 정보를 내포하고 있다고 볼 수 있다. 세번째 주성분의 설명력은 8.26%이다.

iv. 주성분 점수의 산점도

위 표는 첫 번째 주성분과 두 번째 주성분으로 이루어진 주성분 점수 산점도이다.

첫 번째 주 성분은 실주문단가와 총 체결금액, 일종저가, 당일종가 등 주식의 가격에 관한 변수임과 동시에 실제 체결된 가격을 표시하므로, 이는 어떤 한 관측 값이 주식 매입에 대한 최대지불용의를 표시하기 때문에 관측 값의 투자수요를 나타낸다고 볼 수 있다.

왼쪽으로, 투자에 대한 수요도 낮은 축에 속하며, 오른쪽으로 투자 수요도 높은 축에 속한다고 볼 수 있다.




그림 3.2. 첫 번째 주성분과 두 번째 주성분에 대한 주성분 점수 산점도
두 번째 주성분은 총 체결 수량 및 거래 수량과 관련된 변수이다. 이는 한 관측 값이 얼마나 많이 주식을 매입하였느냐를 표시해준다. 관측 값이 주식에 대한 수요가 있고

실제 거래를 체결한다면 본인의 소득 수준 하에서 얼마나 많이 매입할 여유가 있는지를 보여주므로 관측 값의 주식투자 여유자금으로 평가할 수 있다. 위 표에서 위쪽에 위치할수록 체결수량이 작으므로 여유자금이 적은 축에 속하고, 아래에 위치할수록 주식 투자에 여유자금이 많은 축에 속한다고 볼 수 있다.


이러한 관점에서 위 표를 바라보면, 20-30대가 표에 왼쪽에 많이 군집해 있으므로, 주식에 대한 투자수요가 낮다고 볼 수 있고, 표에 오른쪽에 분포한 40대 50대는 투자 수요가 높은 축에 속한다고 볼 수 있다.

또한, 위쪽에 위치한 20-30대는 주식 투자 여유자금이 적은 축에 속하고, 50대는 여유자금이 많은 축에 속하나, 40대는 지역 간 편차가 있으나 대부분 여유자금은 없으나 수요는 많은 축에 분포에 있다.

이에 따라, 경제활동을 막 시작한 20-30대는 주식에 투자할 여유자금이 부족하며, 주식에 대한 투자수요 또한 낮고, 교육비, 주거비 등 지출이 가장 커지는 시기인 40대에는 여유자금은 부족하나, 수요는 높은 것으로 나타났고, 은퇴를 앞둔 50대는 주식 투자의 여유자금이 충분하며, 투자의 대한 수요 또한 높은 것으로 보였다.

특징적인 값으로는 제주,경북,울산,광주 40대가 타 지역에 비해 투자여유자금이 많은 것으로 나타났고, 50대 제주가 여유자금은 가장 많으나, 투자수요가 가장 적은 것으

로 나타났고, 50대 강원도 또한 여유자금은 있으나 투자수요는 적은 것을 보였다.



위 표는 첫 번째 주성분과 세 번째 주성분으로 이루어진 주성분 점수 산점도이다. 첫 번째 주성분은 앞서 말했듯, 주식 투자에 대한 수요를 표시해 준다.


세 번째 주성분은 총 거래대금 및 거래수량이므로 투자처로써 주식의 안정성을 반영하는 것으로 볼 수 있다. 위쪽에 위치할수록 거래대금 및 거래수량이 많으므로 안전자산에 속한다고 볼 수 있고, 아래에 위치할수록 총 거래대금 및 거래수량이 작은 위험자산으로 분리할 수 있다.

이러한 기준으로 세 번째 주성분의 주식의 안정성을 1~3 사이를 고 수준, 1~-1 사이를 중 수준, -1~-3미만을 저수준으로 분리해 보면, 첫 번째 주성분에 의한 투자수요에 상관없이 대부분 중수준에 위험수준의 주식을 선호하는 것으로 평가할 수 있다. 안정성이 높은 주식은 수익률이 낮고, 안정성이 낮은 주식은 수익률이 높은 경향이 있으므로, 대체적으로 중간정도의 안정성과 수익률을 가지는 주식을 선호한다고 볼 수 있다. 즉, 주식에 대한 수요도와 관계없이 대부분 어느 정도의 수익과 안정성을 가지는 균형 잡힌 주식을 선호하는 경향이 크다.

특징적인 값으로는 50대 제주와 강원, 충남과 대구이다. 투자수요가 적은 제주와 강원, 투자수요가 높은 충남과 대구는 각각 주식의 안정성에 대해 정반대의 선호도를 보였다.

제주는 가장 안정적인 투자처를 선호하는데 반해 강원은 안정성이 저수준에 속하는 주식을 선호하였으며, 대구 또한 고수준의 안정성을 띄는 주식을 선호하는데 반해 충

남은 가장 낮은 안정성을 가진 주식을 선호했다.



위 표는 두번째 주성분과 세번째 주성분으로 이루어진 주성분 점수 산점도이다.

두번째 주성분은 주식 투자에 대한 여유자금을 표시하고 있으며, 위 표에선 왼쪽으로 갈 수록 여유자금이 많은 것이다. 세번째 주성분은 주식의 안정성을 표시하고 있으며, 위에서처럼 구간에 따라 고수준, 중수준, 저수준으로 나누어 볼 수 있다.

이에 따라 위 표를 살펴보면, 두 번째 표에서 분석했던 것과 마찬가지로 주식에 투자할 수 있는 여유자금과 관계없이 대부분 안정성과 수익률이 중수준인 주식을 선호하는 것으로 나타났다. 특징적인 값은 두번째 표에서와 같이 50대 제주와 강원, 충남과 대구이다. 여유자금 수준이 높은 축에 속하는데에도 불구하고 제주와 강원 충남과 대구는 안정성에 대한 선호가 반대로 나타났다.

v. 주성분 행렬도

이 때, 확실한 분석을 위해서 주성분 행렬도를 만들면, 그림 3.5와 같은 결과가 나오는 것을 확인할 수 있다.




그림 3.5. 주성분 행렬도

주성분 행렬도의 화살표를 먼저 살펴보면, 화살표의 각도가 가까운 변수들 사이에 큰 상관관계가 있음을 알 수 있고 각도가 먼 변수들은 서로 관련이 작은 변수이다. 즉, 실주문단가, 일종저가, 당일종가 등 주식에 대한 지불용의를 보여주는 변수들 사이에 큰 상관관계가 있고, 총체결수량, 총체결금액, 주문수량 등 주식 투자에 여유자금과 관련된 변수사이에 관계가 있으며, 거래수량과 거래대금 등 총 주식 안정성에 관련된 변수사이에 상관관계가 크다.

또한 세번째 주성분을 이루고있는 거래수량과 거래대금은 고수준, 중수준, 저수준으로 나누어 볼 수 있다.

이를 기준으로 관측치를 파악해보면, 지역에 상관없이 40-50대가 투자수요나 여유자금 면에서 20-30대보다 더 낮다고 볼 수 있다. 20-30대는 경제활동을 막 시작하거나 준비하는 단계이므로 소득이 많지 않고, 노후대비에 대한 동기도 크지 않으므로, 주식투자에 수요 및 여유자금이 작다. 반면 40-50대는 20-30대에 비해 경제활동이 활발히 이루어져 충분한 소득이 있고 노후준비에 대한 동기가 크므로, 주식투자에 대한 수요가 높지만, 동시에 40대는 교육비, 주거비, 양육비 등 지출이 다른 나이 대에 비해 커지는 시기이므로, 주식투자에 여유자금이 부족하다고 볼 수 있다.

그리고 주식에 대한 수요와 여유자금과 관계없이 안정성과 그에 반비례하는 수익률이 균형잡힌 주식을 선호하는 경향이 있다. 예외적으로 50대 제주와 강원은 충분한 자금에 있음에도 불구하고 투자수요가 작다.


이러한 모든 내용을 요약하면 아래의 표와 같다.

20~30대	투자수요가 아주 적고, 여유자금이 아주 적다
40대	투자수요가 많은데 여유자금은 중간
50대	투자수요도 많고, 여유자금도 많고
50대 제주 강원	투자수요가 중간, 여유자금이 많음

4. Factor Analysis (FA)

i. 공동 인자 개수 구하기

앞에서(1. Data Description i. 전반적인 데이터 설명) 우리는 분석을 행할 때 상관행렬을 사용해야한다는 사실을 알 수 있었고, 그러므로, 상관행렬을 스펙트럴 분해하여 설명비율을 구해준 후, 공동 인자의 개수를 확인한다. 그에 대한 수치적 결과는 설명비율로, 시각적인 결과는 Scree Plot을 통해서 확인가능하다.



이 때, 앞에서의 (3. Principal Component Analysis(PCA) ii. 주성분 개수의 선택)의 결과와 같다는 것을 알 수 있는데, 앞에서의 분석과 지금의 분석에서 모두 스펙트럴 분해를 이용하여 분석하였기 때문이다. 세 번째 공동인자까지의 설명비율이 94.724%이고, Scree Plot의 팔꿈치가 3번에서 이루어지는 것을 확인할 수 있으므로, 3개의 공동인자를 사용하여 FA를 수행한다.

이 때, 공통인자 3개를 분석하면 아래와 같이 나온다.

	공통인자1	공통인자2	공통인자3
x1	0.99	0.06	0.11
x2	-0.14	0.97	0.19
x3	-0.14	0.97	0.19
x4	0.30	0.92	0.18
x5	0.99	-0.06	0.09
x6	0.74	-0.14	0.01
x7	0.99	-0.06	0.12
x8	0.99	-0.06	0.10
x9	0.99	-0.06	0.11
x10	-0.88	-0.27	0.33
x11	-0.30	-0.51	0.80

표 4.3. 공통인자 계수


	PC1	PC2	PC3
x1	0.39	0.03	-0.11
x2	-0.05	-0.55	-0.20
x3	-0.05	-0.55	-0.19
x4	0.12	-0.52	-0.19
x5	0.39	0.03	-0.10
x6	0.29	0.08	-0.01
x7	0.39	0.03	-0.13
x8	0.39	0.04	-0.10
x9	0.39	0.04	-0.12
x10	-0.35	0.15	-0.35
x11	-0.12	0.29	-0.84

표 3.3. 주성분 계수


표 4.3은 공통인자 계수를 나타내는 표이다. 이를 앞에 나와 있는 표 3.3의 주성분 계수와 비교해본다. 이 때, 이 결과 값은 위에 제시된 주성분 계수와 추세가 비슷하다고 할 수 있다. 즉, 같은 결과가 나온다는 것을 암시한다. 즉, PCA의 주성분 계수와 PCFA의 공통 인자의 계수의 특징이 비슷하고, 계수들을 서로 비교해 보았을 때, 의미하는 특징들이 주성분 분석과 같다는 것을 알 수 있다.

ii. PCFA

PCFA를 수행하여 인자 적재 그림을 통해 변수들의 특성을 파악해본 후, 인자 점수 그림으로 관측치를 분석하는 절차가 이루어져야 하므로, 우선 인자 적재그림을 통해 변수들의 특성을 파악해본다. 1번째 공통인자와 두 번째 공통인자, 1번째 공통인자와 3번째 공통인자, 2번째 공통인자와 3번째 공통인자에 대한 인자적재그림은 그림 4.2.에서 확인 가능하다.



또한 이에 대한 인자 점수 그림은 그림 4.3에서 확인가능하다.



이 때, 나오는 결과는 위의 주성분 분석과 동일하다는 것을 알 수 있다. 이렇게 PCFA를 진행하는 이유는 앞의 PCA와 결과가 일치하는지를 확인하기 위한 이중검정이었다. 만약 PCFA에서 결과가 달라졌다면 이 연구는 무의미하고, 앞에서 분류한 기준들도 모두 무의미해지지만, 이렇게 PCFA로 다시 검증을 하면서 이 연구가 보다 신뢰성을 얻을 수 있다고 이야기 할 수 있다.

그림 4.4에서는 인자 행렬도를 확인할 수 있다.




그림 4.4. 인자 행렬도

인자행렬도를 그려봤을 때 또한 결과가 비슷하게 나온다.

iii. MLFA

이 때 PCFA에 대한 정당성은 잔차행렬로 파악할 수 있다. 잔차행렬의 원소들이 0으로 수렴해야 성능이 좋다고 판단할 수 있다. 이 때, PCFA의 대부분의 원소들은 0에 수렴하지만, MLFA의 원소들은 0에 수렴하는 원소들이 거의 없고, 심지어 거의 1에 가까운 값들을 가지고 있는 원소들도 많다. 잔차행렬을 보았을 때 PCFA의 성능은 뛰어난 것으로 보인다.

	실주문단가	주문수량	총체결수량	총체결금액	
실주문단가	0.000	-0.001	-0.001	-0.006	
주문수량	-0.001	0.000	0.007	-0.011	
총체결수량	-0.001	0.007	0.000	-0.011	
총체결금액	-0.006	-0.011	-0.011	0.000	
전일종가	0.007	-0.003	-0.002	-0.002	
당일시가	-0.053	0.027	0.024	0.011	
일종고가	0.008	-0.002	-0.002	-0.004	
일종저가	0.007	-0.002	-0.002	-0.004	
당일종가	0.008	-0.002	-0.001	-0.005	
거래수량	-0.001	0.007	0.007	-0.004	
거래대금	-0.003	-0.003	-0.003	0.004	
	전일종가	당일시가	일종고가	일종저가	당일종가
실주문단가	0.007	-0.053	0.008	0.007	0.008
주문수량	-0.003	0.027	-0.002	-0.002	-0.002
총체결수량	-0.002	0.024	-0.002	-0.002	-0.001
총체결금액	-0.002	0.011	-0.004	-0.004	-0.005
전일종가	0.000	-0.051	0.006	0.008	0.007
당일시가	-0.051	0.000	-0.051	-0.056	-0.058
일종고가	0.006	-0.051	0.000	0.006	0.008
일종저가	0.008	-0.056	0.006	0.000	0.008
당일종가	0.007	-0.058	0.008	0.008	0.000
거래수량	-0.003	0.061	-0.001	-0.002	-0.002
거래대금	-0.001	-0.008	-0.003	-0.002	-0.003
	거래수량	거래대금			
실주문단가	-0.001	-0.003			
주문수량	0.007	-0.003			
총체결수량	0.007	-0.003			
총체결금액	-0.004	0.004			
전일종가	-0.003	-0.001			
당일시가	0.061	-0.008			
일종고가	-0.001	-0.003			
일종저가	-0.002	-0.002			
당일종가	-0.002	-0.003			
거래수량	0.000	-0.021			
거래대금	-0.021	0.000			

표 4.4. 자차행렬


표 4.4. 잔차행렬


이 때, 우리는 MLFA를 수행해야할 정당성을 얻지 못한다. MLFA는 다변량 정규성을 만족해야 시행할 수 있는데, 앞에서 데이터가 다변량 정규성을 만족하지 못한다는 사실을 알 수 있었고, 잔차행렬로 검정도 해보았을 때, 더욱 MLFA를 하지 말아야 한다는 주장에 힘을 실어준다.

5. Cluster Analysis (CA)


i. 계층적 군집분석

군집분석에는 여러 가지 연결법이 존재하는데, 이를 크게 두 부류로 나누면 계층적 연결법과 비 계층적 연결법이다. 이 때 모든 연결법은 표준화 유클리드 거리와 마할라노비스 거리를 이용하였다. 계층적 연결법은 단일연결법, 완전연결법, 평균연결법, 와드연결법이 존재한다. 이 때, 가장 대중화된 단일연결법과 와드연결법을 사용하기로 한다. 비 계층적 연결법에는 K-평균법과 K-중위수법이 존재하는데, 여기에서, 가장 많이 사용하는 K-연결법을 사용하기로 한다. 단일 연결법을 시행한 결과는 그림 9.1에 있다.






단일 연결법으로는 군집 형성이 힘들다는 것을 알 수 있지만, 와드 연결법으로는 8개 정도의 군집이 나타나는 것을 확인할 수 있다.



마할라노비스 거리를 이용한 단일 연결법




마할라노비스 거리를 이용한 와드 연결법

그림 5.2. 마할라노비스 거리를 이용한 단일 연결법과 와드 연결법

마할라노비스 거리를 이용해도 단일 연결법으로는 군집을 도출할 수 없었지만, 와드 연결법으로는 8개 정도의 군집이 형성되는 것을 볼 수 있다.

하지만, 군집수를 추정하기 위한 더 좋은 방법은, ccc와 Dindex등을 이용하는 것이다. 이에 대한 결과는 그림 9.3에 있다. 비록 표준화 유클리드 거리와 마할라노비스 거리를 이용하여 군집을 5개정도 형성할 수 있을 것이라고 유추해볼 수 있지만, 더 확실하게 파악하기 위해서는 여러 측도들을 사용해야 한다.



우선 ccc를 이용하여 군집의 수를 추정할 때는 ccc값이 가장 큰 경우의 군집수를 사용하면 되는데, 이 때, ccc가 가장 큰 값은 군집의 수가 4개 일 때이다. Dindex 그래프의 경우 기울기가 급격히 감소하는 구간(빨간 선 그래프), 기울기가 급격히 증가하는 구간(파란 선 그래프)로 군집의 수를 선택하는데, 이 때, 급격히 감소하는 구간은 군집의 수가 6인 구간이라고 할 수 있다. 즉, ccc와 Dindex에서는 군집이 4~6개의 군비이 가장 좋은 분석이라고 판단된다.

하지만 모든 측도들을 고려해보면, 아래의 표 5.1에서 확인할 수 있다.

<pre> ***** * Among all indices: * 6 proposed 2 as the best number of clusters * 6 proposed 3 as the best number of clusters * 5 proposed 4 as the best number of clusters * 6 proposed 8 as the best number of clusters ***** conclusion ***** * According to the majority rule, the best number of clusters is 2 ***** </pre>
표 5.1. 모든 측도를 활용한 군집의 수 결정

이 때, 6개의 측도에서 2개의 군집으로 나누는 것이 가장 좋다고 이야기하였으며, 그 다음은 3개의 군집으로 나누는 것이 가장 좋은 분석이라고 평가하고 있다. 이 때 2

개, 3개의 군집으로 나누면 군집이 너무 크게 나누어지므로 특징을 파악할 수 없고, 4개로 추천해주는 측도보다 8의 군집으로 나누는 것을 추천하는 측도가 훨씬 많으므로, 우리는 8개의 측도로 나누어서 관측치의 특성을 파악할 것이다.

ii. 비계층적 군집분석

계층적 연결법에서, 군집을 8개로 나누는 것이 가장 효과적이라고 판단하였다. (물론, 2개의 군집으로 나눈 것이 가장 효율적이라는 결과를 얻었지만, 2개로 나누었을 때 관측치들의 특성이 전혀 나타나지 않으므로, 2번째로 효율이 좋은 8개의 군집으로 나누는 방법을 사용한다.) 이 때, K-평균법을 사용하여 군집을 나누어주면 표 5.2과 같은 결과를 얻는다.

	관측치
그룹 1	40대 강원, 40대 대전, 40대 전남, 40대 충북 50대 경기, 50대 광주, 50대 대구, 50대 대전, 50대 충남
그룹 2	50대 제주
그룹 3	40대 경북, 40대 광주, 40대 대구, 40대 부산, 40대 서울, 40대 울산, 40대 제주, 40대 충남 50대 경남, 50대 경북, 50대 부산, 50대 서울, 50대 인천
그룹 4	50대 강원, 50대 울산, 50대 전남, 50대 전북, 50대 충북
그룹 5	30대 경북, 30대 서울, 30대 충남, 40대 경기
그룹 6	20대 서울, 20대 울산, 30대 강원, 30대 경기, 30대 광주, 30대 대구, 30대 울산, 30대 인천, 30대 전북, 30대 제주, 30대 충북 40대 경남, 40대 인천, 40대 전북
그룹 7	20대 대전, 20대 제주, 30대 대전, 30대 부산, 30대 전남
그룹 8	20대 강원, 20대 경기, 20대 경남, 20대 경북, 20대 광주, 20대 대구, 20대 부산, 20대 인천, 20대 전남, 20대 전북, 20대 충남, 20대 충북 30대 경남
표 5.2. K-평균법 결과	

또한, 각 군집에 대한 특성을 나타낸 표는 표 5.3에서 확인할 수 있다.

Group.1	실수분단가	수분수량	총체결수량	총체결금액	전일총가	당일시가
1	1	9.863140	2.656385	2.649649	12.60755	9.822590
2	2	8.596189	6.398595	6.221584	14.59371	8.440528
3	3	9.584181	2.917068	2.898517	12.63214	9.513645
4	4	9.364579	3.907219	3.893404	13.24595	9.301533
5	5	9.469577	2.581305	2.559552	12.31834	9.390848
6	6	9.217401	2.543786	2.540985	12.05929	9.155013
7	7	9.403592	2.317627	2.317627	11.75043	9.313402
8	8	9.062481	2.511253	2.511253	11.72913	8.983904
일증고가 일증저가 당일총가 거래수량 거래대금						
1		9.911806	9.784970	9.853883	15.00958	24.75981
2		8.686261	8.440528	8.554682	16.54567	25.06056
3		9.645424	9.467849	9.552683	15.19772	24.84543
4		9.411437	9.237469	9.335535	15.10713	24.47224
5		9.540457	9.333205	9.441534	15.60378	25.09564
6		9.273220	9.116953	9.196710	15.63696	24.89352
7		9.462953	9.275273	9.385199	15.69034	25.06601
8		9.122021	8.950384	9.027753	15.89879	24.96661

표 5.3. 각 군집에 대한 특성(로그 변환 전)

로그 변환을 해제하면 아래와 같다.

Group.1	실주문단가	주문수량	총체결수량	총체결금액	전일총가
1	1	76913726397	5707.898	5609.298	5.221005e+13
2	2	3946291823	25037729.004	16656498.581	3.923841e+15
3	3	38987682442	11984.796	11019.054	5.524827e+13
4	4	26159491414	141922.884	141163.562	2.307612e+14
5	5	29990180632	4783.327	4644.696	2.183177e+13
6	6	16585886477	4633.016	4521.269	1.518579e+13
7	7	25597048916	2129.764	2129.764	6.181456e+12
8	8	11663352253	3721.517	3721.517	5.891567e+12
당일시가 일증고가 일증저가 당일총가 거래수량 거래대금					
1		74066084628	85352910092	64741406924	74748247185
2		3083184096	4855798231	2757579910	3586589195
3		31895045763	44696230134	29819412463	36243239110
4		23434401545	29211795593	19310356141	24479921676
5		28010832399	35578107097	21851924947	28074160231
6		15443385208	18872973167	13187510838	15835141798
7		23409278304	29426349051	19010592679	24606407887
8		10391180651	13392698838	9020792990	10751731550

표 5.4 각 군집에 대한 특성

6. 결론

다음 표는 K-평균법 결과로 도출된 각각 군집들의 특성을 나타낸 표에서 각각의 주 성분과 높은 연관성을 가진 변수들을 추출하여 군집들간 순위를 나타낸 표이다. 변수와 가장 높은 관련도를 띠는 변수를 1번으로 두고 각각을 비교한 뒤, 합계를 내어 최종 순위를 내리는 방식으로 합계가 가장 적은 그룹이 주성분과 가장 높은 연관성을 가진 것 이라고 할 수 있다.

<표 10.5 두번째 주성분 변수 순위표>									
변수 그룹	x1	x4	x5	x6	x7	x8	x9	합계	순위
Group 1	1	4	1	1	1	1	1	10	1
Group 2	8	1	8	8	8	8	8	49	7
Group 3	2	3	2	3	2	2	2	16	2
Group 4	5	2	5	5	5	5	5	32	5
Group 5	3	5	3	2	3	3	3	22	3
Group 6	6	6	6	6	6	6	6	42	6
Group 7	4	7	4	4	4	4	4	31	4
Group 8	7	8	7	7	7	7	7	50	8

먼저 <표 10.5>는 첫번째 주성분과 관련된 변수로 각각의 변수들은 전일종가 당일시가 일종저고가등 주식의 가격과 관련된 변수로 주당 주식의 시장가치 및 주당 거래자의 최대 지불용의이므로 이를 주식에 대한 수요도라는의미로 해석했다. 즉 주식이 높은 가격임에도 불구하고 지불용의가 있다는 것은 그만큼 거래자가 자본재로서 주식을 높게 평가하고 수요함을 의미한다고 보는 것이다.

이를 기준으로 정리했을 때, 앞서 본 결과들과 같이 40-50대가 다수 포진한 그룹(그룹1,그룹3,그룹5)이 가장 높은 순위를 차지했다. 다른 통계 결과로 내린 추정과 마찬가지로 대부분의 40-50대가 주식에 대한 수요가 다른 나이대에 비해 크다고 볼 수 있다.

다만 예외적으로 50대 강원,울산,전남,전북,충북은 20-30대 대전,제주,부산,전남 그룹보다 낮은 등수를 보여주었고, 50대 중에서는 제주가 가장 낮은 순위를 차지했다.

20-30대에서는 경북,서울,충남 지역이 타지역의 20-30대에 비해 순위가 높은 그룹에 속했고 경남지역은 20대와 30대 모두 가장 순위가 가장 낮은 그룹에 속하므로 20-30대 통틀어 주식에 대한 수요가 가장 낮다고 볼 수 있다.

지역 사이에는 경남과 경북지역 충남과 충북으로 지역 간 차이가 있다는 것을 볼 수 있다.

나이대별로 나누어보면 대전,충남 지역이 가장 높은 등수를 차지했다.

<표 10.6 두번째 주성분 변수 순위표>

변수 그룹	x2	x3	x4	합계	순위
Group 1	4	4	4	12	4
Group 2	1	1	1	3	1
Group 3	3	3	3	9	3
Group 4	2	2	2	6	2
Group 5	5	5	5	15	5
Group 6	6	6	6	18	6
Group 7	8	8	7	23	8
Group 8	7	7	8	22	7

표10.6은 두 번째 주성분에 영향을 미치는 변수와 그룹사이의 관계를 순위로 나타낸 표이다.

두 번째 주성분은 주식 주문수량과 총체결수량 및 총체결한금액과 관련된 변수로 전반적으로 주식의 총 구매 수량 및 총 시장가치를 반영한 변수이므로 주식을 구매할 수 있는 여유자금의 크기로 해석했다.

이를 바탕으로 위 표를 통해 알 수 있듯이 40-50대가 속한 그룹(그룹1,그룹2,그룹3,그룹4)가 주식에 대한 수요가 높은 것으로 해석된 것과 마찬가지로 20-30대보다 여유자금의 크기가 더 큰 것으로 보였다. 40대보단 50대가 더 많이 속한 그룹이 높은 등수를 기록했다. 앞선 표에서 다소 낮은 등수를 보였던 50대 제주와 강원,울산,전남,전북,충북지역도 여유자금 측면에선 높은 등수를 기록했다. 또한 20대가 속한 그룹보다 30대가 속한 그룹이 더 높은 등수를 기록했다. 프랑코 모델라이니의 생애주기 가설에 따른 일반적인 소득의 생애주기를 고려해봤을 때, 나이대별 고정적인 소득 수준과 지출 수준에 따른 결과로 해석할 수 있다.

지역별로 큰 차이를 보이는 것은 앞서 마찬가지로 경북지역과 경남지역이었다.

나이대별로 순위를 정리해 봤을 때, 서울지역이 50대를 제외한 모든 나이대에서 가장 높은 순위를 기록했고, 30대 경북,서울,충남은 40대 경남,인천,전북보다 더 높은 순위를 기록했다.

<표 10.7> 세 번째 주성분 변수 순위표

그룹 \ 변수	x10	x11	합계	순위
Group 1	8	7	15	7(2)
Group 2	1	3	4	1
Group 3	6	6	12	6
Group 4	7	8	15	7(2)
Group 5	5	1	6	3(2)
Group 6	4	5	9	5
Group 7	3	2	5	2
Group 8	2	4	6	3(2)

마지막 표는 세 번째 주성분과 관련된 변수이고, 이는 거래수량과 거래대금을 나타내 주는 변수이다. 거래수량과 거래대금이 많은 주식일수록 우량주에 가깝기 때문에 세 번째 주성분은 앞 서, 주식의 안정성을 보여주는 지표로 해석하였다. 위 표를 통해 40-50대가 20-30대에 비해 비교적 위험선호적이라고 볼 수 있다.

이러한 모든 내용을 정리한 것이 아래의 표와 같다.

연령	수요	자산	안정성
50대	1등:충남,대전,대구,광주,경기 2등:경남,경북,부산,서울,인천 3등:강원,울산,전남,전북,충북 4등:제주	1등:제주 2등:강원,울산,전남,전북,충북 3등:경남,경북,부산,서울,인천 4등:경기,광주,대구,대전,충남	1등:제주 2등: 경남, 경북, 부산, 서울, 인천 3등:경기, 광주, 대구, 대전,충남, 강원, 울산, 전남, 전북, 충북
40대	1등:강원,대전,전남,충북 2등:경북,광주,대구,부산,서울,울산,제주,충남 3등:경기 4등:경남,인천,전북	1등: 경북, 광주, 대구, 부산, 서울, 울산, 제주, 충남 2등: 강원, 대전, 전남, 충북 3등: 경기 4등: 경남, 인천, 전북	1등 : 경기 2등: 경남, 인천, 전북 3등: 경북, 광주, 대구, 부산, 서울, 울산, 제주, 충남 4등: 강원, 대전, 전남, 충북
30대	1등:경북,서울,충남	1등: 경북, 서울, 충남	1등 대전, 부산, 전남

	2등:대전,부산,전남 3등:강원,경기,광주,대구,울산,인천,전북,제주,충북 4등:경남	2등:강원,경기,광주,대구,울산,인천,전북,제주,충북 3등:경남 4등: 대전, 부산, 전남	2등: 경북, 서울, 충남, 경남 3등:강원, 경기, 광주,대구, 울산, 인천, 전북, 제주, 충북
20대	1등:대전,제주 2등:서울,울산 3등:강원,경기,경남,경북,광주,대구,부산,인천,전남,전북,충남,충북	1등:서울, 울산, 2등:강원,경기,경남,경북,광주,대구,부산,인천,전남,전북,충남,충북 3등:대전,제주	1등:대전, 제주, 2등: 강원, 경기, 경남, 경북, 광주, 대구, 부산, 인천, 전남, 전북, 충남, 충북

C. 결론

이러한 특징들을 주식에 대한 수요, 주식에 대한 여유자금, 안전성 선호도, 생활수준과 미래대비로 변수를 설정하고, 그에 해당하는 값은 1(높음), 2(다소높음), 3(다소낮음), 4(낮음)으로 순위를 매겨서 데이터를 작성하여 CA를 시키면 훨씬 더 정확한 분석을 할 수 있다. CA에 대한 절차는 위와 같은 방식으로 진행하고, 비계층적 군집분석을 진행하기 이전에 여러 가지 척도로 어느 정도의 집단의 개수가 필요한지 판단한다.

<pre> * Among all indices: * 4 proposed 2 as the best number of clusters * 7 proposed 3 as the best number of clusters * 1 proposed 5 as the best number of clusters * 6 proposed 6 as the best number of clusters * 2 proposed 7 as the best number of clusters * 3 proposed 8 as the best number of clusters ***** conclusion ***** </pre>	
그림 C.1. 순위형 데이터에 대한 군집에 대한 척도 결과	

그 결과, 3개와 6개의 군집이 제일 적절하다는 평가를 받는데, 우리는 3개의 군집은 이 데이터를 표현하기에 너무 적은 것으로 판단하여, 6개의 군집이 적절하다고 판단하고, K-평균법을 통하여 결론을 도출하였다.

이 때, 도출한 결과에 따르면, 군집은 아래와 같이 나뉜다.

<C.표1.두 데이터를 통합했을 때의 군집 분할>

그룹 1	주식에 대한 수요가 다소 높음 주식에 대한 자산이 높음 안정성 성향 다소 높음 낮은 생활수준요구 미래 대비도가 낮음	20대 서울, 20대 울산
	주식에 대한 수요가 다소 낮음 주식에 대한 자산이 다소 높음 안정성 성향이 다소 높음 낮은 생활수준 요구 미래 대비도가 낮음	20대 강원, 20대 경기, 20대 경남 20대 경북, 20대 광주, 20대 대구 20대 부산, 20대 인천, 20대 전남 20대 전북, 20대 충남, 20대 충북
	주식에 대한 수요가 높음 주식에 대한 자산이 다소 낮음 안정성 성향이 다소 낮음	30대 울산

	낮은 생활수준 요구 미래 대비도가 낮음	
	주식에 대한 수요가 낮음 주식에 대한 자산이 다소 낮음 안정성 성향이 다소 높음 낮은 생활수준 요구 미래 대비도가 낮음	30대 경남
그룹 2	주식에 대한 수요가 높음 주식에 대한 자산이 다소 낮음 안정성 성향이 높음 낮은 생활수준 요구 미래 대비도가 낮음	20대 대전, 20대 제주
	주식에 대한 수요가 다소 높음 주식에 대한 자산이 낮음 안정성 성향이 높음 낮은 생활수준 요구 미래 대비도가 낮음	30대 대전
	주식에 대한 수요가 다소 높음 주식에 대한 자산이 낮음 안정성 성향이 높음 다소 높은 생활수준 요구 미래 대비도가 다소 높음	30대 부산
	주식에 대한 수요가 다소 높음 주식에 대한 자산이 낮음 안정성 성향이 높음 다소 낮은 생활수준 요구 미래 대비도가 다소 낮음	30대 전남
	주식에 대한 수요가 높음 주식에 대한 자산이 높음 안정성 성향이 다소 높음 다소 낮은 생활수준 요구 미래 대비도가 다소 낮음	30대 경북
그룹 3	주식에 대한 수요가 높음 주식에 대한 자산이 높음 안정성 성향이 다소 높음 높은 생활수준 요구 미래 대비도가 높음	30대 서울
	주식에 대한 수요가 높음	30대 충남

	주식에 대한 자산이 높음 안정성 성향이 다소 높음 다소 높은 생활수준 요구 미래 대비도가 다소 높음	
	주식에 대한 수요가 다소 높음 주식에 대한 자산이 높음 안정성 성향이 다소 낮음 높은 생활수준 요구 미래 대비도가 높음	40대 서울
	주식에 대한 수요가 다소 낮음 주식에 대한 자산이 다소 낮음 안정성 성향이 높음 다소 높은 생활수준 요구 미래 대비도가 다소 높음	40대 경기
그룹 4	주식에 대한 수요가 낮음 주식에 대한 자산이 낮음 안정성 성향이 다소 높음 다소 낮은 생활수준 요구 미래 대비도가 다소 낮음	40대 경남, 40대 전북
	주식에 대한 수요가 낮음 주식에 대한 자산이 낮음 안정성 성향이 다소 높음 다소 높은 생활수준 요구 미래 대비도가 다소 높음	40대 인천
	주식에 대한 수요가 낮음 주식에 대한 자산이 높음 안정성 성향이 높음 높은 생활수준 요구 미래 대비도가 높음	50대 제주
	주식에 대한 수요가 다소 높음 주식에 대한 자산이 다소 낮음 안정성 성향이 다소 높음 다소 낮은 생활수준 요구 미래 대비도가 다소 낮음	50대 경남, 50대 경북
그룹 5	주식에 대한 수요가 다소 높음 주식에 대한 자산이 다소 낮음 안정성 성향이 다소 높음 다소 높은 생활수준 요구	50대 부산, 50대 인천

그룹 6	미래 대비도가 다소 높음	
	주식에 대한 수요가 다소 높음 주식에 대한 자산이 다소 낮음 안정성 성향이 다소 높음 높은 생활수준 요구 미래 대비도가 높음	50대 서울
	주식에 대한 수요가 높음 주식에 대한 자산이 낮음 안정성 성향이 다소 낮음 다소 낮은 생활수준 요구 미래 대비도가 다소 낮음	50대 경기, 50대 광주 50대 충남
	주식에 대한 수요가 높음 주식에 대한 자산이 낮음 안정성 성향이 다소 낮음 다소 높은 생활수준 요구 미래 대비도가 다소 높음	50대 대구, 50대 대전
	주식에 대한 수요가 다소 낮음 주식에 대한 자산이 다소 높음 안정성 성향이 다소 낮음 다소 낮은 생활수준 요구 미래 대비도가 다소 낮음	30대 강원, 30대 전북 30대 충북, 50대 강원 50대 울산, 50대 전남 20대 전북, 50대 충북
	주식에 대한 수요가 다소 낮음 주식에 대한 자산이 다소 높음 안정성 성향이 다소 낮음 다소 높은 생활수준 요구 미래 대비도가 다소 높음	30대 경기, 30대 광주 30대 대구, 30대 인천 30대 제주
	주식에 대한 수요가 높음 주식에 대한 자산이 다소 높음 안정성 성향이 낮음 다소 낮은 생활수준 요구 미래 대비도가 다소 낮음	40대 강원, 40대 전남 40대 충북
	주식에 대한 수요가 다소 높음 주식에 대한 자산이 높음 안정성 성향이 다소 낮음 다소 낮은 생활수준 요구 미래 대비도가 다소 낮음	40대 경북, 40대 광주 40대 충남
	주식에 대한 수요가 다소 높음 주식에 대한 자산이 높음	40대 대구

	안정성 성향이 다소 낮음 다소 높은 생활수준 요구 미래 대비도가 다소 높음	
	주식에 대한 수요가 높음 주식에 대한 자산이 다소 높음 안정성 성향이 낮음 다소 높은 생활수준 요구 미래 대비도가 다소 높음	40대 대전
	주식에 대한 수요가 다소 높음 주식에 대한 자산이 높음 안정성 성향이 다소 낮음 다소 높은 생활수준 요구 미래 대비도가 다소 높음	40대 부산, 40대 울산 40대 제주

결국 이를 통해서 지역/연령별 주식에 대한 수요, 주식에 대한 자산, 안정성 성향, 생활수준 요구정도, 미래대비도를 파악할 수 있다.

4. 기대효과

지역 및 연령별 가계자금 및 금융자산 데이터를 활용한 분석 통해 표 6.1~6.4에 해당하는 지역 및 연령별 소비와 미래에 대한 정보를 파악할 수 있었고, 동학 개미 운동 신규 고객 투자 정보를 활용하여 지역 및 연령별 주식 상품에 수요 및 투자 여유자금과 안정성과 수익성 사이의 선호도를 파악할 수 있었다. 그리고 두 데이터를 결합하여 각 특징에 맞는 군집을 도출해냄으로써 소비와 주식투자에 대한 새로운 데이터를 생성하였다. 위와 같은 데이터를 활용한 기대효과는 다음과 같다.

1. 각 군집의 특징에 맞는 적절한 주식 상품의 구성의 가능성

투자자의 연령 및 지역별 특징에 따라 적절한 주식 상품을 구성하여 판촉하기 용이해질 것이다. 가령 40대를 겨냥한 주식 상품을 구성한다면, 투자 여유 자산이 많고 안전성보다 수익성을 선호하는 40대 경북과 투자 여유 자산이 적고 안전성을 선호하는 40대 경남은 상품의 구성이 달라질 것이고, 높은 생활수준을 요구하고, 미래 대비가 높은 40대 대전과 이와 정반대인 40대 충남은 주식 상품 판촉을 위한 전략이 달라질 것이다. 즉, 지역 및 연령별 특징을 파악함으로써 상품 판매를 위한 더 효율적이고 매력적인 구성이 가능해질 것이다.

2. 역선택 감소의 가능성

위와 같은 통계 데이터를 통해 도출된 결과를 통해 소비자 또한 자신이 속한 집단의 소비성향과 미래에 대한 대비 정도와 주식에 대한 수요 및 여유자금과 안전성에 대한 선호 등의 정보를 획득하고, 이를 개개인의 상황과 비교하며, 이에 알맞게 추천된 주식 상품들을 비교해봄으로써 시장 내에 역선택의 가능성을 감소시킬 수 있을 것이다. 이를 통해 개개인의 상황과 맞지 않게 구성된 주식 상품은 자연스럽게 시장에서 퇴출되고, 효율적인 상품만 남음으로써 시장 내 양화를 구축할 가능성을 열 수 있을 것이다.

3. 주식상품 판매 수익 개선의 가능성

1번과 2번의 가능성이 실현된다면, 이에 따라 시장 내에 2가지 효과가 기대된다. 1) 각 군집의 특징에 맞는 주식 상품만 공급하게 되므로 불필요한 주식 상품의 공급이 줄어 비용 절감 2) 제공된 정보를 바탕으로 소비자에 정보의 비대칭이 해소되고, 진입장벽이 낮아져 시장 내 수요 증가. 따라서 위 두 가지를 효과를 고려해본다면, 주식 상품 판매 수익의 개선 가능성이 있다고 볼 수 있다.

위와 같은 기대효과가 발생하지 않을 가능성도 분명 존재한다. 위 데이터들은 중위값을 기준으로 분석했으므로 개개인의 특징과 선호를 정확하게 반영할 수는 없기 때문이다. 하지만, 투자 정보와 가계자금 및 금융자산 데이터를 통해 연령 및 지역별 소비자의 대략적인 특성을 파악해보고, 이를 각각의 군집으로 분류할 수 있음을 보였다는 점에서 의미 있는 데이터라고 볼 수도 있다.

결론적으로 아래와 같이 투자성향에 맞는 상품을 파악할 수 있을 것이다.

<4.표1.두 데이터를 통합했을 때 투자 성향에 대한 상품 파악>

20대 강원	주식에 대한 낮은 수요, 보통의 여유자금, 보통의 안전성 추구가 특징이다. 주식 상품에 대한 적극적인 홍보가 필요하며, 적당한 비용으로 투자할 수 있는 안전성과 수익성이 균형 잡힌 주식 상품을 추천해 주는 편이 좋을 것이다.
20대 경기	주식에 대한 낮은 수요, 보통의 여유자금, 보통의 안전성 추구가 특징이다. 주식 상품에 대한 적극적인 홍보가 필요하며, 적당한 비용으로 투자할 수 있는 안전성과 수익성이 균형 잡힌 주식 상품을 추천해 주는 편이 좋을 것이다.
20대 경남	주식에 대한 낮은 수요, 보통의 여유자금, 보통의 안전성 추구가 특징이다. 주식 상품에 대한 적극적인 홍보가 필요하며, 적당한 비용으로 투자할 수 있는 안전성과 수익성이 균형 잡힌 주식 상품을 추천해 주는 편이 좋을 것이다.
20대 경북	주식에 대한 낮은 수요, 보통의 여유자금, 보통의 안전성 추구가 특징이다. 주식 상품에 대한 적극적인 홍보가 필요하며, 적당한 비용으로 투자할 수 있는 안전성과 수익성이 균형 잡힌 주식 상품을 추천해 주는 편이 좋을 것이다.
20대 광주	주식에 대한 낮은 수요, 보통의 여유자금, 보통의 안전성 추구가 특징이다. 주식 상품에 대한 적극적인 홍보가 필요하며, 적당한 비용으로 투자할 수 있는 안전성과 수익성이 균형 잡힌 주식 상품을 추천해 주는 편이 좋을 것이다.
20대 대구	주식에 대한 낮은 수요, 보통의 여유자금, 보통의 안전성 추구가 특징이다. 주식 상품에 대한 적극적인 홍보가 필요하며, 적당한 비용으로 투자할

	수 있는 안전성과 수익성이 균형 잡힌 주식 상품을 추천해 주는 편이 좋을 것이다.
20대 대전	주식에 대한 높은 수요, 적은 여유자금, 매우 높은 안전성 추구가 특징이다. 따라서 적은 비용으로 높은 안전성을 추구할 수 있는 주식상품을 추천해주는 편이 좋을 것이다.
20대 부산	주식에 대한 낮은 수요, 보통의 여유자금, 보통의 안전성 추구가 특징이다. 주식 상품에 대한 적극적인 홍보가 필요하며, 적당한 비용으로 안전성과 수익성이 균형 잡힌 주식 상품을 추천해 주는 편이 좋을 것이다.
20대 서울	주식에 대한 다소 높은 수요, 많은 여유자금, 낮은 안전성 추구가 특징이다. 따라서 많은 비용이 들고, 안전성이 낮더라도, 높은 수익성을 추구할 수 있는 주식상품을 추천해주는 편이 좋을 것이다.
20대 울산	주식에 대한 다소 높은 수요, 많은 여유자금, 낮은 안전성 추구가 특징이다. 따라서 많은 비용이 들고, 안전성이 낮더라도, 높은 수익성을 추구할 수 있는 주식상품을 추천해주는 편이 좋을 것이다.
20대 인천	주식에 대한 낮은 수요, 보통의 여유자금, 보통의 안전성 추구가 특징이다. 주식 상품에 대한 적극적인 홍보가 필요하며, 적당한 비용으로 투자할 수 있는 안전성과 수익성이 균형 잡힌 주식 상품을 추천해 주는 편이 좋을 것이다.
20대 전남	주식에 대한 낮은 수요, 보통의 여유자금, 보통의 안전성 추구가 특징이다. 주식 상품에 대한 적극적인 홍보가 필요하며, 적당한 비용으로 투자할 수 있는 안전성과 수익성이 균형 잡힌 주식 상품을 추천해 주는 편이 좋을 것이다.
20대 전북	주식에 대한 낮은 수요, 보통의 여유자금, 보통의 안전성 추구가 특징이다. 주식 상품에 대한 적극적인 홍보가 필요하며, 적당한 비용으로 투자할 수 있는 안전성과 수익성이 균형 잡힌 주식 상품을 추천해 주는 편이 좋을 것이다.
20대 제주	주식에 대한 높은 수요, 적은 여유자금, 매우 높은 안전성 추구가 특징이다. 따라서 적은 비용으로 높은 안전성을 추구할 수 있는 주식상품을 추천해주는 편이 좋을 것이다.
20대 충남	주식에 대한 낮은 수요, 보통의 여유자금, 보통의 안전성 추구가 특징이다. 주식 상품에 대한 적극적인 홍보가 필요하며, 적당한 비용으로 투자할 수 있는 안전성과 수익성이 균형 잡힌 주식 상품을 추천해 주는 편이 좋을 것이다.
20대	주식에 대한 낮은 수요, 보통의 여유자금, 보통의 안전성 추구가 특징

충북	이다. 주식 상품에 대한 적극적인 홍보가 필요하며, 적당한 비용으로 투자할 수 있는 안전성과 수익성이 균형 잡힌 주식 상품을 추천해 주는 편이 좋을 것이다.
----	--

30대 강원	대출이 많지 않지만, 미래에 대한 대비를 어느정도 하는 30대 강원은 주식에 대한 수요는 다소 낮으며, 주식 투자에 여유자금은 다소 많으면서, 위험성이 따르는 주식을 선호하는 경향이 있다. 따라서 투자처로 주식상품에 대해 알리고, 다소 위험성이 따르지만 수익성이 높은 주식상품을 추천하는 편이 낮다.
30대 경기	대출을 많이 해야하고, 미래에 대한 대비를 어느 정도 하는 30대 경기는 주식에 대한 수요는 다소 낮으며, 주식 투자에 여유자금은 다소 많으면서, 위험성이 따르는 주식을 선호하는 경향이 있다. 따라서 투자처로 주식상품에 대해 알리고, 다소 위험성이 따르지만, 수익성이 높은 주식상품을 추천하는 편이 낮다.
30대 경남	소비가 높고, 미래에 대한 준비도가 낮은 30대 경남은 주식 투자에 대한 낮은 수요와 다소 적은 여유자금을 가지고 있으며, 안전성이 다소 높은 주식을 선호하는 경향이 있다. 따라서 주식상품을 적극 홍보할 필요가 있으며, 적은 비용으로 투자할 수 있는 안전성이 다소 높은 자산을 추천하는 편이 좋을 것이다.
30대 경북	대출이 많지 않지만, 미래에 대한 대비를 어느정도 하는 30대 경북은 주식에 대한 높은 수요와, 많은 여유자금, 다소 높은 안전성 추구가 특징이다. 특히 대출이 많지 않으면서 주식에 대한 수요도 높고, 여유자금도 많은 유일한 지역이다. 많은 비용이 들더라도, 안전성과 수익성이 보장되는 주식상품을 추천해주는 편이 좋을 것이다.
30대 광주	대출을 많이 해야하고, 이에 따른 미래에 대한 준비도가 다소 높은 30대 광주는 주식에 대한 다소 낮은 수요와, 다소 많은 여유자금, 위험이 따르는 주식 선호라는 특징을 가진다. 따라서, 주식상품에 대한 홍보가 필요하며, 비용이 어느정도 들고 위험이 따르더라도, 수익성이 보장되는 주식상품을 추천해주는 편이 좋을 것이다.
30대 대구	대출을 많이 해야하고, 이에 따른 미래에 대한 준비도가 다소 높은 30대 대구는 주식에 대한 다소 낮은 수요와, 다소 많은 여유자금, 위험이 따르는 주식 선호라는 특징을 가진다. 따라서, 주식상품에 대한 홍보가 필요하며, 비용이 어느정도 들고 위험이 따르더라도, 수익성이 보장되는 주식상품을 추천해주는 편이 좋을 것이다.
30대 대전	소비가 높고, 미래에 대한 준비도가 낮은 30대 대전은 주식에 대한 다소 높은 수요와 적은 여유자금을 보이고 있으며, 안전성이 매우 높은 주식을 선호하는 경향이 있다. 따라서 적은 비용으로 매우 높은 안전

	성을 보이는 주식상품을 추천하는 편이 좋을 것이다.
30대 부산	대출을 많이 해야하고, 이에 따른 미래에 대한 준비도가 다소 높은 30대 부산은 다소 높은 주식수요, 적은 보유자금, 매우 높은 안전성 추구가 특징이다. 따라서 적은 비용으로 투자할 수 있으며, 높은 안전성이 기대되는 주식상품을 추천하는 편이 좋을 것이다.
30대 서울	대출을 많이하고 그에 따라 미래에 대한 준비를 많이 하는 30대 서울은 다른 지역의 30대보다 높은 주식수요와 많은 여유자금을 띄는 것이 특징이며, 안전성이 다소 높은 주식상품을 선호하는 경향이 있다. 따라서 비용이 많이 들더라도, 안정성이 높은 주식상품을 추천하는 편이 좋을 것이다.
30대 울산	소비가 높고, 미래에 대한 준비도가 낮은 30대 울산은 다소 낮은 주식수요와 다소 높은 여유자금을 보이고 있으며, 안전성이 낮은 고수익주식을 선호하는 경향이 있다. 따라서 다소 위험성이 따르지만 수익성이 좋은 주식 상품을 추천하는 편이 좋을 것이다.
30대 인천	대출을 많이 해야하고, 이에 따른 미래에 대한 준비도가 다소 높은 30대 인천은 주식에 대한 다소 낮은 수요와, 다소 많은 여유자금, 위험이 따르는 주식 선호라는 특징을 가진다. 따라서, 주식상품에 대한 홍보가 필요하며, 비용이 어느정도 들고 위험이 따르더라도, 수익성이 보장되는 주식상품을 추천해주는 편이 좋을 것이다.
30대 전남	대출이 많지 않지만, 미래에 대한 대비를 어느정도 하는 것으로 나타나는 30대 전남은 주식에 대한 수요가 다소 높고, 여유자금은 적고, 안전한 주식을 선호하는 경향이 있다. 따라서 적은 비용으로 투자할 수 있는 상품이나, 안전하지만 수익성은 다소 낮은 주식상품을 추천하는 편이 낫다.
30대 전북	대출이 많지 않지만, 미래에 대한 대비를 어느정도 하는 30대 전북은 주식에 대한 수요는 다소 낮으며, 주식 투자에 여유자금은 다소 많으면서, 위험성이 따르는 주식을 선호하는 경향이 있다. 따라서 투자처로 주식상품에 대해 알리고, 다소 위험성이 따르지만 수익성이 높은 주식상품을 추천하는 편이 낫다.
30대 제주	대출을 많이 해야하고, 이에 따른 미래에 대한 준비도가 다소 높은 30대 제주는 주식에 대한 다소 낮은 수요와, 다소 많은 여유자금, 위험이 따르는 주식 선호라는 특징을 가진다. 따라서, 주식상품에 대한 홍보가 필요하며, 비용이 어느정도 들고 위험이 따르더라도, 수익성이 보장되는 주식상품을 추천해주는 편이 좋을 것이다.
30대 충남	대출을 많이 해야하고, 이에 따른 미래에 대한 준비도가 다소 높은 30대 충남은 주식에 대한 높은 수요와 많은 여유자금 보유, 다소 높은 안전성을 추구하는 것이 특징이다. 따라서 비용이 많이 들더라도, 안

	전성과 수익성을 균형있게 추구할 수 있는 상품을 추천해주는 편이 좋을 것이다.
30대 충북	대출이 많지 않지만, 미래에 대한 대비를 어느정도 하는 30대 충북은 주식에 대한 수요는 다소 낮으며, 주식 투자에 여유자금은 다소 많으면서, 위험성이 따르는 주식을 선호하는 경향이 있다. 따라서 투자처로 주식상품에 대해 알리고, 다소 위험성이 따르지만 수익성이 높은 주식상품을 추천하는 편이 낫다.

40대 강원	주식에 대한 수요가 높고, 주식에 대한 자산이 다소 높으며, 안정성이 낮은 상품에 투자하고자 한다. 이는 강원의 40대가 안정적인 재산 상태를 가지고 미래를 어느 정도 준비하는 것으로 보아, 주식에는 관심을 크게 가지고 있고, 많은 자산을 주식에 투자하고자 하며, 많은 수익을 창출하려는 것으로 보인다. 많은 돈을 투입하면서 위험은 감수하지만 수익이 크게 나는 상품을 추천하는 것이 좋을 것이다.
40대 경기	주식에 대한 수요가 다소 낮고, 주식에 대한 자산이 다소 낮으며, 안정성이 높은 상품에 투자하고자 한다. 수요와 자산이 다소 낮은 이유는 대출을 많이 해야 하는 광역시, 즉 그 곳에 사려면 높은 생활수준을 유지해야하는 광역시이기 때문이다. 이로 인해서 안정성이 높은 상품을 원하는 것으로 보인다. 적은 돈으로 안정적인 수입을 가져다 줄 수 있는 상품을 추천하는 것이 좋을 것이다.
40대 경남	주식에 대한 수요가 낮고, 주식에 대한 자산이 낮으며, 안정성이 다소 높은 상품에 투자하고자 한다. 하지만, 이 지역의 경우 높은 생활수준을 유지 하지 않아도 그 지역에서 생활을 할 수 있는 광역시이다. 즉, 돈이 부족해서 주식을 하지 않는 것이 아니라, 주식에 대한 정보의 부족으로 투자를 하지 않는다고 볼 수 있다. 이 지역은 안정성이 어느 정도 있는 상품을 홍보하는 것이 필요하다.
40대 경북	주식에 대한 수요가 다소 낮고, 주식에 대한 자산이 높으며, 안정성이 다소 낮은 상품에 투자하고자 한다. 이 지역의 경우 주식에 대한 수요가 낮은 이유는 높은 생활수준을 그 지역에서 요구하기 때문이다. 하지만, 미래에 대한 준비는 어느 정도 하는 지역으로, 어느 정도의 위험을 가지고 자산을 더 많이 모으려고 한다. 이 지역에서는 많은 돈을 투입하면서 위험을 감소하지만 수익이 안정자산 보다 더 큰 상품을 추천해야 한다.
40대 광주	주식에 대한 수요가 다소 높고, 주식에 대한 자산이 높으며, 안정성이 다소 낮은 상품에 투자하고자 한다. 이 지역의 경우 보통정도의 생활수준을 요구하기에, 수요가 다소 높고 주식에 대한 자산도 높다. 하지만, 안정성이 다소 낮다. 이 말의 의미는, 주식을 통해서 자산을 많이 모으려고 하는 성격이 강한 지역이라는 것이다. 많은 돈을 투입하면서

	위험을 감수하지만, 안정자산보다 수입이 더 큰 상품을 추천해야 한다.
40대 대구	주식에 대한 수요가 다소 높고, 주식에 대한 자산이 높으며, 안정성이 다소 낮은 상품에 투자하고자 한다. 이 지역의 경우 다소 높은 생활수준을 요구하는데 반해, 수요가 다소 높고 주식에 대한 자산도 높다 하지만, 안정성이 다소 낮다. 이 말의 의미는, 주식을 통해서 자산을 많이 모으려고 하는 성격이 강한 지역이라는 것이다. 많은 돈을 투입하면서 위험을 감소하지만, 안정자산보다 수입이 더 큰 상품을 추천해야 한다.
40대 대전	주식에 대한 수요가 높고, 주식에 대한 자산이 다소 높으며, 안정성이 낮은 상품에 투자하고자 한다. 이 때, 주식에 대한 수요와 자산이 높은 이유는 미래에 대한 준비를 어느 정도 하기 때문이다. 즉, 다소 높은 생활수준을 유지하는 지역이므로, 이 지역에서 계속 생활하기 위해서 주식에서 큰 수익을 내려고 한다. 이 지역에는 많은 돈을 투입하면서 위험을 감수하면서 수입이 큰 상품을 추천해야 한다.
40대 부산	주식에 대한 수요가 다소 높고, 주식에 대한 자산이 높으며, 안정성이 다소 낮은 상품에 투자하고자 한다. 이 때, 주식에 대한 수요와 자산이 높은 이유는 미래에 대한 준비를 어느 정도 하기 때문이다. 즉, 다소 높은 생활수준을 유지하는 지역이므로, 이 지역에서 계속 생활하기 위해서 주식에서 큰 수익을 내려고 한다. 이 지역에는 많은 돈을 투입하면서 위험을 감수하면서 수익이 큰 상품을 추천해야 한다.
40대 서울	주식에 대한 수요가 다소 높고, 주식에 대한 자산이 높으며, 안정성이 다소 낮은 상품에 투자하고자 한다. 이 지역은 높은 생활수준을 유지해야 하는 지역임에도 불구하고, 주식에 대한 수요가 높고 자산이 높다는 것은, 이 지역의 생활수준을 유지하기 위해서 자산을 축적하겠다는 것으로 보인다. 이 지역에는 많은 돈을 투입하면서 위험을 감수하고, 수익이 큰 상품을 추천해야 한다.
40대 울산	주식에 대한 수요가 다소 높고, 주식에 대한 자산이 높으며, 안정성이 다소 낮은 상품에 투자하고자 한다. 이 지역은 어느정도 높은 생활수준을 유지해야하는 지역임에도 불구하고, 주식에 대한 수요와 자산이 높으며, 안정성이 낮은 상품을 추구한다. 이 지역은 많은 돈을 투입하면서 위험을 감수하고 수익이 큰 상품을 추천해야 한다.
40대 인천	주식에 대한 수요가 낮고, 주식에 대한 자산이 다소 낮으며, 안정성이 다소 높은 상품에 투자하고자 한다. 이 지역은 어느정도 높은 생활수준을 유지해야 하는 지역이기 때문에, 그 유지 비용으로 인하여 주식에 대한 수요가 낮고 자산도 낮다. 또한, 돈을 잃지 않기 위해 자산에 대한 안정성을 추구한다. 이러한 지역은 작은 가격으로 안정적인 상품을 추천해야 한다.

40대 전남	주식에 대한 수요가 높고, 주식에 대한 자산이 다소 높으며, 안정성이 낮은 상품에 투자하고자 한다. 이 지역의 경우 생활수준 유지비용이 크지 않으므로, 주식에 대한 수요와 자산이 높다. 또한 안정성도 낮다. 여유가 있는 투자자들이기 때문에, 많은 돈을 투입하면서 위험을 감수하고 수익이 큰 상품을 추천해야 한다.
40대 전북	주식에 대한 수요가 낮고, 주식에 대한 자산이 낮으며, 안정성이 다소 높은 상품에 투자하고자 한다. 이 지역의 경우, 생활 수준을 유지하는 비용이 크지 않은데 주식에 대한 수요가 낮고 자산이 낮은 경향을 보인다. 또한 안정성이 높은 주식에 투자한다. 이 경우, 주식에 대한 정보의 부족으로 인한 것으로 보인다. 안정성이 있는 낮은 가격의 투자 상품을 적극적으로 홍보해야 한다.
40대 제주	주식에 대한 수요가 다소 높고, 주식에 대한 자산이 높으며, 안정성이 다소 낮은 상품에 투자하고자 한다. 이 지역은 높은 생활수준을 유지해야 하는 지역임에도 불구하고, 주식에 대한 수요가 높고 자산이 높다는 것은, 이 지역의 생활수준을 유지하기 위해서 자산을 축적하겠다는 것으로 보인다. 이 지역에는 많은 돈을 투입하면서 위험을 감수하고, 수익이 큰 상품을 추천해야 한다.
40대 충남	주식에 대한 수요가 다소 높고, 주식에 대한 자산이 높으며, 안정성이 다소 낮은 상품에 투자하고자 한다. 지역은 어느정도 높은 생활수준을 유지해야하는 지역임에도 불구하고, 주식에 대한 수요와 자산이 높으며, 안정성이 낮은 상품을 추구한다. 이 지역은 많은 돈을 투입하면서 위험을 감수하고 수익이 큰 상품을 추천해야 한다.
40대 충북	주식에 대한 수요가 높고, 주식에 대한 자산이 다소 높으며, 안정성이 낮은 상품에 투자하고자 한다. 지역은 어느정도 높은 생활수준을 유지해야하는 지역임에도 불구하고, 주식에 대한 수요와 자산이 높으며, 안정성이 낮은 상품을 추구한다. 이 지역은 많은 돈을 투입하면서 위험을 감수하고 수익이 큰 상품을 추천해야 한다.
50대 강원	안정된 생활수준을 영위하는 50대 강원은 주식에 대한 낮은 수요, 다소 높은 여유자금, 안전성보단 수익성을 추구하는 것이 특징이다. 먼저 주식상품에 대한 많은 홍보가 필요하며, 다소 자금이 많이 들고, 위험성이 따르더라도 수익성이 높은 상품을 추천해주는 편이 좋을 것이다.
50대 경기	안정된 생활수준을 영위하는 50대 경기는 주식에 대한 수요가 매우 높으나, 여유자금은 적으며, 안전성보단 수익성을 추구하는 것이 특징이다. 따라서 작은 자금으로 운용 가능하며, 위험이 따르더라도 수익성을 추구할 수 있는 상품을 추천해 주는 편이 좋을 것이다.
50대 경남	안정된 생활수준을 영위하는 50대 경남은 다소 높은 주식수요, 다소 낮은 여유자금, 적당한 안전성 추구라는 특징을 보인다. 적당한 자금

	으로 운용할 수 있고, 수익성이 높은 주식상품을 추천해주는 것이 좋을 것이다.
50대 경북	안정된 생활수준을 영위하는 50대 경남은 다소 높은 주식수요, 다소 낮은 여유자금, 적당한 안전성 추구라는 특징을 보인다. 적당한 자금으로 운용할 수 있고, 수익성이 높은 주식상품을 추천해주는 것이 좋을 것이다.
50대 광주	안정된 생활수준을 영위하는 50대 경기는 주식에 대한 수요가 매우 높으나, 여유자금은 적으며, 안전성보단 수익성을 추구하는 것이 특징이다. 따라서 작은 자금으로 운용 가능하며, 위험이 따르더라도 수익성을 추구할 수 있는 상품을 추천해 주는 편이 좋을 것이다.
50대 대구	안정된 생활수준보다 높은 생활수준을 영위하는 50대 대구는 주식에 대한 높은 수요, 적은 여유자금과 수익성을 추구하는 경향이 있다. 따라서 적은 자금으로도 운용할 수 있는 안전성 보단 수익성에 초점을 둔 주식상품을 추천하는 편이 좋을 것 같다.
50대 대전	안정된 생활수준보다 높은 생활수준을 영위하는 50대 대전은 주식에 대한 높은 수요, 적은 여유자금과 수익성을 추구하는 경향이 있다. 따라서 적은 자금으로도 운용할 수 있는 안전성 보단 수익성에 초점을 둔 주식상품을 추천하는 편이 좋을 것 같다.
50대 부산	안정된 생활수준보다 높은 생활수준을 영위하는 50대 부산은 주식에 대한 다소 높은 수요와 다소 적은 여유자금을 가지고 있으며, 다소 높은 안전성을 추구하는 것이 특징이다. 따라서 적은 자금으로도 운용할 수 있는 어느정도 안전성에 초점을 둔 주식상품을 추천하는 편이 좋을 것이다.
50대 서울	많은 대출과 저축을 하며 타 지역에 비해 높은 생활 수준을 영유하는 50대 서울은 다소 높은 주식 수요와, 다소 낮은 주식 여유자금, 적당한 안전성을 추구하는 것이 특징이다. 이에 따라 적은 자금으로 안정성과 수익성이 균형잡힌 주식상품을 추천해 주는 편이 좋을 것이다.
50대 울산	안정된 생활수준을 영위하는 50대 울산은 주식에 대한 낮은 수요, 다소 높은 여유자금, 안전성보단 수익성을 추구하는 것이 특징이다. 먼저 주식상품에 대한 많은 홍보가 필요하며, 다소 자금이 많이 들고, 위험성이 따르더라도 수익성이 높은 상품을 추천해주는 편이 좋을 것이다.
50대 인천	안정된 생활수준보다 높은 생활수준을 영위하는 50대 부산은 주식에 대한 다소 높은 수요와 다소 적은 여유자금을 가지고 있으며, 다소 높은 안전성을 추구하는 것이 특징이다. 따라서 적은 자금으로도 운용할 수 있는 어느정도 안전성에 초점을 둔 주식상품을 추천하는 편이 좋을 것이다.
50대	안정된 생활수준을 영위하는 50대 전남은 주식에 대한 낮은 수요, 다

전남	소 높은 여유자금, 안전성보단 수익성을 추구하는 것이 특징이다. 먼저 주식상품에 대한 많은 홍보가 필요하며, 다소 자금이 많이 들고, 위험성이 따르더라도 수익성이 높은 상품을 추천해주는 편이 좋을 것이다.
50대 전북	안정된 생활수준을 영위하는 50대 전북은 주식에 대한 낮은 수요, 다소 높은 여유자금, 안전성보단 수익성을 추구하는 것이 특징이다. 먼저 주식상품에 대한 많은 홍보가 필요하며, 다소 자금이 많이 들고, 위험성이 따르더라도 수익성이 높은 상품을 추천해주는 편이 좋을 것이다.
50대 제주	많은 대출과 저축을 하며 타 지역에 비해 높은 생활 수준을 영유하는 50대 제주는 주식에 대한 낮은 수요, 많은 여유자금, 높은 안전성 추구라는 특징을 가지고 있다. 따라서 주식상품을 적극적으로 홍보하는 것이 우선이고, 안전성이 매우 높은 주식상품을 추천해주는 편이 좋을 것이다.
50대 충남	안정된 생활수준을 영위하는 50대 경기는 주식에 대한 수요가 매우 높으나, 여유자금은 적으며, 안전성보단 수익성을 추구하는 것이 특징이다. 따라서 작은 자금으로 운용 가능하며, 위험이 따르더라도 수익성을 추구할 수 있는 상품을 추천해 주는 편이 좋을 것이다.
50대 충북	안정된 생활수준을 영위하는 50대 충북은 주식에 대한 낮은 수요, 다소 높은 여유자금, 안전성보단 수익성을 추구하는 것이 특징이다. 먼저 주식상품에 대한 많은 홍보가 필요하며, 다소 자금이 많이 들고, 위험성이 따르더라도 수익성이 높은 상품을 추천해주는 편이 좋을 것이다.

즉, 이러한 특징대로 투자를 권유하는 것이 좋다는 판단이 나온다. 연령, 성별에 따른 선호하는 상품이 모두 다르다는 것을 알기 때문에, 위의 표를 기준으로 해서 투자를 권유하면, 위의 기대효과를 충족시킬 수 있을 것이다.

5. 활용 데이터

- [1] '지역 및 연령별 10대소비(가계자금) 금액 및 금융자산 데이터', 농협은행
- [2] '[2021금융데이터경진대회] 동학개미운동 신규 고객 투자 정보', 한국투자증권

6. 참고자료

- [1] 최용석, R과 함께하는 다변량 자료분석, 경문사(2018)

2021 년 8 월 31 일
참가자(대표자) 안 중 찬 (인) 또는 서명)
금융보안원 귀중